

语言学形式化教程

From Natural Language to Formal Systems

MS Roslyn

2026 年 8 月 3 日

摘要

本教程系统介绍语言学的核心领域及其形式化方法，涵盖语言起源与分类、形式语言理论、形态学、句法学、语义学、音系学、计算语言学，并在最后一章集中讨论不同语言之间的差异。通过数学公式、自动机理论和逻辑演算，展示语言学如何像数学一样进行精确的形式化分析，并说明语言差异如何在共享的深层结构上以参数化的方式呈现。

目录

1 语言学的起源与历史	10
1.1 语言学的定义与研究对象	10
1.2 古代语言研究	10
1.2.1 印度传统: 波你尼与梵语语法	10
1.2.2 希腊传统: 词类与逻辑	11
1.2.3 中国训诂学: 小学传统	11
1.2.4 阿拉伯传统: 西伯维与早期音系学	11
1.3 现代语言学的诞生	11
1.3.1 历史比较语言学 (19 世纪)	11
1.3.2 结构主义语言学 (20 世纪初)	12
1.4 生成语法的革命	12
1.4.1 从规则到原则与参数	13
1.5 认知语言学与功能学派	13
1.5.1 认知语言学	13
1.5.2 功能语言学	13
1.6 计算语言学时代	14
1.7 本章小结	14
2 语言的分类	15
2.1 分类的两条路径	15
2.2 谱系分类	15
2.2.1 比较法与同源词	15
2.2.2 谱系树模型与波浪模型	15
2.2.3 世界主要语系	16
2.2.4 语系的层次结构	16
2.3 类型学分类: 按词法类型	16
2.3.1 孤立语 (Isolating)	16
2.3.2 黏着语 (Agglutinative)	17
2.3.3 屈折语 (Fusional)	17
2.3.4 多式综合语 (Polysynthetic)	17
2.4 类型学分类: 按句法类型	18
2.4.1 基本语序	18
2.4.2 类型学相关性: 头参数	18
2.5 形式化类型学特征	19

2.5.1	蕴含层级与标记性	19
2.6	语言接触与混合	19
2.6.1	语言联盟 (Sprachbund)	19
2.6.2	皮钦语与克里奥尔语	20
2.7	语言演化模型	20
2.8	本章小结	20
3	形式化语言基础	21
3.1	形式语言理论概述	21
3.2	字母表与字符串	21
3.2.1	基本定义	21
3.2.2	字符串的基本运算	21
3.2.3	语言作为集合	22
3.3	文法与乔姆斯基层级	22
3.3.1	形式文法定义	22
3.3.2	乔姆斯基层级	22
3.4	正则语言 (Type-3)	23
3.4.1	正则表达式	23
3.4.2	有限状态自动机 (FSA)	23
3.5	上下文无关文法 (Type-2)	24
3.5.1	CFG 定义	24
3.5.2	句法树	24
3.5.3	歧义与二义性文法	25
3.5.4	范式	25
3.6	下推自动机与上下文无关语言	25
3.7	上下文有关文法 (Type-1)	26
3.8	形式语言与自然语言	26
3.8.1	自然语言的复杂度	26
3.8.2	依存语法	27
3.9	形式语义基础	27
3.9.1	Lambda 演算	27
3.10	本章小结	27
4	词法 (形态学)	28
4.1	形态学概述	28
4.2	语素类型	28

4.2.1	按独立性	28
4.2.2	按功能	28
4.3	屈折 (Inflection)	29
4.3.1	屈折的性质	29
4.3.2	屈折范畴	29
4.3.3	屈折的跨语言差异	29
4.4	派生 (Derivation)	30
4.4.1	派生的性质	30
4.4.2	派生与屈折的对比	30
4.5	构词方式总览	30
4.6	组合型构词	31
4.6.1	复合 (Compounding)	31
4.6.2	重叠 (Reduplication)	32
4.6.3	拟声词 (Onomatopoeia)	33
4.6.4	专名转化 (Eponym)	33
4.7	缩短型构词	34
4.7.1	截短 (Clipping)	34
4.7.2	逆构词 (Back-formation)	34
4.7.3	缩写 (Abbreviation)	35
4.7.4	混成 (Blending)	36
4.8	词类转换与语义构词	36
4.8.1	转类 (Conversion)	36
4.8.2	语义造词: 词义变化 (Semantic Change)	37
4.8.3	比喻造词: 隐喻与转喻	37
4.9	借词: 外来词的吸收	38
4.9.1	音译 (Transliteration)	38
4.9.2	意译 (Semantic Translation)	38
4.9.3	仿译 (Calque)	39
4.9.4	音义兼译 (Phono-Semantic Matching)	39
4.9.5	借形 (Borrowing of Written Form)	39
4.9.6	语义借用 (Semantic Loan)	40
4.10	汉语的造字法: 六书	40
4.11	构词方式的跨语言对比	41
4.12	形态音位学	42
4.12.1	英语复数规则	42
4.12.2	语素变体 (Allomorph)	42

4.13	形态分析的形式化	42
4.13.1	有限状态形态学	42
4.13.2	双层面模型	43
4.14	构词规则的形式化	43
4.14.1	语素顺序约束	43
4.14.2	形态生成的图论表示	43
4.15	形态类型学的形式刻画	44
4.16	本章小结	44
5	句法	45
5.1	句法概述	45
5.2	短语结构语法	45
5.2.1	基本短语规则	45
5.2.2	句法树示例	46
5.2.3	短语结构语法的类型学参数	46
5.3	X-bar 理论	46
5.3.1	头参数与跨语言差异	47
5.4	依存语法	47
5.4.1	依存关系类型	48
5.4.2	依存语法的跨语言优势	48
5.5	转换生成语法	48
5.5.1	深层结构与表层结构	48
5.5.2	Wh-移动	48
5.5.3	孤岛约束	49
5.6	最简方案	49
5.6.1	合并 (Merge)	49
5.6.2	移动是合并的副产品	49
5.7	范畴语法	50
5.7.1	组合范畴语法 (CCG)	50
5.7.2	组合规则	50
5.8	树邻接文法 (TAG)	50
5.9	概率句法分析	51
5.9.1	概率上下文无关文法 (PCFG)	51
5.9.2	CKY 算法	51
5.10	跨语言的句法参数	51
5.11	本章小结	52

6 语义学	53
6.1 语义学概述	53
6.2 词义关系	53
6.2.1 基本关系	53
6.3 形式语义学	53
6.3.1 模型论语义	53
6.3.2 真值条件语义	54
6.3.3 谓词逻辑翻译	54
6.4 Lambda 演算与组合语义	54
6.4.1 Lambda 演算基础	54
6.4.2 词项语义	55
6.4.3 组合示例	55
6.5 量词语义	55
6.5.1 广义量词	55
6.5.2 量词作用域	56
6.6 内涵语义	56
6.6.1 可能世界语义	56
6.6.2 模态算子	56
6.6.3 命题态度	56
6.7 时间与体态语义	57
6.7.1 时态与时间论域	57
6.7.2 体态 (Aspect)	57
6.8 词汇语义表示	57
6.8.1 框架语义	57
6.8.2 论元结构 (Theta 角色)	57
6.8.3 语用与语义的边界: 预设与含义	58
6.9 跨语言的语义共性	58
6.10 本章小结	58
7 音系学与语音学	59
7.1 语音学 vs 音系学	59
7.2 国际音标 (IPA)	59
7.2.1 元音系统	59
7.3 区别特征	60
7.4 音系规则	60
7.4.1 SPE 规则格式	60

7.4.2	英语复数规则	60
7.5	音位与音位变体	61
7.6	音节结构	61
7.6.1	音节模板的跨语言差异	62
7.7	声调与重音	62
7.7.1	声调语言	62
7.7.2	重音语言	62
7.7.3	日语是声调还是重音语言?	63
7.8	韵律与语调	63
7.9	优选论 (Optimality Theory)	63
7.9.1	OT 框架	63
7.9.2	约束的类型	63
7.9.3	OT 与跨语言差异	64
7.10	语音变化与历时音系学	64
7.10.1	常见的音变	64
7.10.2	汉语语音史	64
7.11	本章小结	64
8	计算语言学	65
8.1	概述	65
8.2	语言模型	65
8.2.1	N-gram 模型	65
8.2.2	最大似然估计	65
8.2.3	平滑技术	65
8.2.4	语言模型与语言差异	66
8.3	词性标注	66
8.3.1	隐马尔可夫模型 (HMM)	66
8.3.2	Viterbi 算法	66
8.3.3	词性标注的跨语言差异	67
8.4	词向量表示	67
8.4.1	分布语义假说	67
8.4.2	Word2Vec	67
8.4.3	词向量类比	67
8.4.4	多语言词向量	68
8.5	句法分析	68
8.5.1	依存分析	68

8.5.2	转移系统	68
8.5.3	跨语言依存分析: Universal Dependencies	68
8.6	Transformer 与注意力	68
8.6.1	自注意力机制	68
8.6.2	多头注意力	69
8.6.3	位置编码	69
8.7	大语言模型	69
8.7.1	语言建模目标	69
8.7.2	缩放定律	70
8.7.3	多语言模型	70
8.8	机器翻译	70
8.8.1	统计机器翻译	70
8.8.2	神经机器翻译	70
8.9	评估指标	70
8.9.1	困惑度 (Perplexity)	70
8.9.2	BLEU 分数	71
8.9.3	跨语言评估的挑战	71
8.10	计算语言学与语言学的相互反哺	71
8.11	本章小结	71
9	跨语言比较: 不同语言的差异	72
9.1	比较语言的维度	72
9.2	语音层面的差异	72
9.2.1	音位库存的规模差异	72
9.2.2	送气对立: 一音两用 vs 两音对立	73
9.2.3	声调的有无	73
9.2.4	音节结构差异	73
9.3	词法层面的差异	74
9.3.1	形态类型谱系	74
9.3.2	名词的性: 语义 vs 语法	74
9.3.3	格的系统: 从语序到词形	74
9.3.4	动词的时体系统	75
9.4	句法层面的差异	75
9.4.1	基本语序	75
9.4.2	头参数: 语序的系统性	75
9.4.3	主语优先 vs 话题优先	76

9.4.4	Pro-省略 (主语省略)	76
9.4.5	疑问句的形成	77
9.4.6	Wh-疑问词的位置	77
9.4.7	关系从句	77
9.5	代词、敬语与礼貌系统	77
9.5.1	第二人称的复杂性差异	77
9.5.2	敬语系统: 日语的极端例子	78
9.6	文字系统的差异	78
9.6.1	文字类型学	78
9.6.2	汉字与拼音文字的结构差异	78
9.6.3	文字与语言结构的互动	79
9.7	词汇与语法化的差异	79
9.7.1	词义切分的不同	79
9.7.2	语法化的差异	79
9.8	形式化: 原则与参数理论	79
9.8.1	语言差异 = 参数取值	79
9.8.2	跨语言共性与蕴含层级	80
9.9	语言相对性: 差异是否影响思维?	80
9.9.1	萨丕尔-沃尔夫假说	80
9.9.2	相对论的实验证据	80
9.9.3	现代计算的视角	81
9.10	语言差异的量化比较	81
9.11	本章小结	81

1 语言学的起源与历史

1.1 语言学的定义与研究对象

语言学 (Linguistics) 是系统研究人类语言的学科，其研究对象涵盖语言的多个层面：

- 语音 (Phonetics): 语音的物理与生理属性
- 音系 (Phonology): 语音在特定语言系统中的组织方式
- 词法 (Morphology): 词的内部结构与构词规则
- 句法 (Syntax): 词组合成短语和句子的规则
- 语义 (Semantics): 语言单位的意义
- 语用 (Pragmatics): 语言在语境中的使用

语言学不仅是人文学科，更是一门交叉科学。它与数学共享形式化方法 (集合论、自动机理论、逻辑演算)，与计算机科学共同构成自然语言处理 (NLP) 的理论基础，与心理学、神经科学共同研究语言的认知与神经基础。正是这种形式化的追求，使语言学区别于一般的人文研究：它试图用精确的符号系统描述语言规律，正如数学描述自然规律。

1.2 古代语言研究

1.2.1 印度传统: 波你尼与梵语语法

公元前 4 世纪，印度语法学家波你尼 (Pāṇini) 在《八章书》(Aṣṭādhyāyī) 中建立了梵语语法的 3,959 条规则。这是人类历史上最早的、堪称完整的形式化语法体系。其特点包括：

- 采用类似生成的方式：从有限规则推导出一切合法形式
- 规则间有明确的优先级和相互作用机制
- 定义了语素、词干、词缀的操作系统 (类似现代的形态音位学)

波你尼的规则系统可以用现代形式语言理论的方式表述：

$$\text{规则: } X \rightarrow Y \quad \text{在条件 } C \text{ 下} \quad (1)$$

其规则网络与乔姆斯基层级中上下文敏感的文法规则 (见形式语言一章) 在思想上有深刻的一致性，因此波你尼被一些学者称为“生成语法的鼻祖”。

1.2.2 希腊传统: 词类与逻辑

古希腊学者最早将语言与逻辑联系起来。亚里士多德区分了名词 (ónoma) 和动词 (rhēma), 并注意到”真与假”只有通过命题 (句子) 才能表达, 从而将语言研究与逻辑学结合。斯多葛学派进一步区分了”被说出的声音””被表达的内容”与”外部事物”, 初步萌芽了后来能指/所指的区分。

1.2.3 中国训诂学: 小学传统

中国古代的”小学”包含文字学、音韵学、训诂学三个分支:

- **文字学:** 分析汉字的构造。许慎《说文解字》(约公元 100 年) 创立了 540 部首体系, 并总结出象形、指事、会意、形声、转注、假借”六书”理论, 是第一部分析汉字结构的系统著作。
- **音韵学:** 研究汉语的语音系统, 以”反切”注音法、《切韵》《广韵》等韵书为代表。
- **训诂学:** 解释古语词义, 《尔雅》是其鼻祖。

1.2.4 阿拉伯传统: 西伯维与早期音系学

公元 8 世纪, 波斯学者西伯维 (Sibawayh) 在《书》(Al-Kitāb) 中对阿拉伯语进行了详尽的描述性分析, 尤其是对辅音的音位对立、发音部位和语音环境做了系统的分类。他的工作被公认为早期音系学的典范, 比欧洲的类似研究早了一千多年。

1.3 现代语言学的诞生

1.3.1 历史比较语言学 (19 世纪)

19 世纪的历史比较语言学标志着语言学成为一门独立的经验科学。其核心方法是比较法 (Comparative Method): 通过比较亲属语言中规律对应的同源词 (cognates), 重建它们的祖语。

格里姆定律 (Grimm's Law) 描述了从原始印欧语 (PIE) 到日耳曼语族的系统性辅音转移:

$$\text{PIE } *p \rightarrow \text{Gmc } f \quad (2)$$

$$\text{PIE } *t \rightarrow \text{Gmc } \theta \quad (3)$$

$$\text{PIE } *k \rightarrow \text{Gmc } h \quad (4)$$

维尔纳定律 (Verner's Law) 后来解释了格里姆定律的例外 (清音变浊擦音取决于原始重音位置), 体现了”规律无例外, 例外有规律”的科学原则。由此, 历史语言学确立

了音变的规律性假设:

如果语言 L_1, L_2 同源, 则存在系统的语音对应: $f: \Sigma_{L_1} \rightarrow \Sigma_{L_2}$ (5)

1.3.2 结构主义语言学 (20 世纪初)

瑞士语言学家费迪南·德·索绪尔 (Ferdinand de Saussure) 在《普通语言学教程》中奠定了结构主义的基础:

- **能指 (Signifier) 与所指 (Signified):** 语音形象与概念之间是任意、约定俗成的关系
- **语言 (Langue) 与言语 (Parole):** 语言系统 vs. 具体的话语行为
- **共时 (Synchronic) 与历时 (Diachronic) 研究:** 系统状态的描写 vs. 历史演变

索绪尔的核心洞见是: 语言是一个系统, 其中每个单位的价值由它在系统中的对立关系决定。这一思想后来被形式化为“结构即关系之网络”。

结构主义在布拉格学派 (特鲁别茨柯伊、雅柯布森) 手中发展为功能结构主义。特鲁别茨柯伊 (Trubetzkoy) 提出了音位 (phoneme) 概念: 一个语言系统中能区分意义的最小语音单位。音位正是通过对立 (opposition) 来定义的:

$$\text{音位} = \frac{\text{语音特征}}{\text{区别意义的最小对立}} \quad (6)$$

美国结构主义 (布龙菲尔德 Bloomfield) 则强调描写主义与分布分析, 主张基于语料对语言进行严格的、可操作的分析。

1.4 生成语法的革命

诺姆·乔姆斯基 (Noam Chomsky) 在 1957 年《句法结构》中发起了生成语法革命, 其核心理念:

- 语言具有**普遍语法** (Universal Grammar, UG): 人类天生的语言官能
- 句法是**生成性**的: 有限的规则系统可以生成无限的合法句子
- **区分能力 (Competence) 与表现 (Performance):** 内在的语言知识 vs. 实际的使用行为
- **刺激贫乏论 (Poverty of the Stimulus):** 儿童从有限的输入中习得复杂的语法, 说明语言知识有先天基础

生成语法把语言学研究从”收集语料、分类描写”转向”建立可以生成一切合法句子、排除一切非法句子的规则系统”。这一目标与形式语言理论完全一致：

$$G = \langle V_N, V_T, P, S \rangle \quad (7)$$

其中 V_N 是非终结符集合, V_T 是终结符集合, P 是产生式规则集合, S 是起始符号。生成语法所生成的语言就是

$$L(G) = \{w \in V_T^* \mid S \Rightarrow^* w\} \quad (8)$$

1.4.1 从规则到原则与参数

生成语法自身也在不断演进：从早期规则系统 (短语结构规则 + 转换规则), 到原则与参数理论 (Principles and Parameters), 再到最简方案 (Minimal Program)。原则与参数理论认为：人类语言共享一组普遍原则 (原则), 而语言之间的差异只是少数参数 (parameters) 取值不同。这为”语言之间的差异”提供了形式化的解释框架, 我们将在最后一章详细展开。

1.5 认知语言学与功能学派

20 世纪后期, 学界出现了对”纯形式句法”的反拨：

1.5.1 认知语言学

认知语言学强调语言与一般认知能力密不可分：

- 语言是**认知能力**的一部分, 而非独立模块
- **隐喻**是思维的基本机制 (Lakoff & Johnson, 1980): 概念隐喻 (如”争论是战争”) 塑造语言表达
- 语法是**用法为基础** (Usage-based) 的: 语法结构是从具体语言使用中抽象出来的
- **构式语法** (Construction Grammar): 把”词素-词-短语-句式”都看作”形式-意义”配对体

1.5.2 功能语言学

功能学派 (韩礼德 Halliday 的系统功能语法等) 强调语言的功能：

- **概念功能**: 语言如何表征世界
- **人际功能**: 语言如何建立社会关系
- **语篇功能**: 语言如何组织信息

1.6 计算语言学时代

21 世纪以来，语言学与计算机科学深度融合：

- 统计方法 (n-gram, HMM) 使语言处理变得可计算
- 神经网络方法 (Word2Vec, Transformer) 让机器自动学习语言结构
- 大语言模型 (LLMs) 在几乎全部语言任务上达到接近人类的水平

语言的描写从定性走向定量，从手工规则走向数据驱动。形式化程度不断提高，而语言学理论 (类型学、形态音位学、依存语法) 也在现代 NLP 系统中找到了落地的形态。语言学至此完成了一次螺旋上升：古代的形式化直觉、19 世纪的经验实证、20 世纪的结构与生成理论、21 世纪的计算实现。

1.7 本章小结

语言学的发展经历了”形式化直觉 (古代)→ 系统描写 (19 世纪)→ 结构分析 (20 世纪初)→ 生成理论 (20 世纪中)→ 认知与功能并重 (20 世纪后期)→ 计算实现 (21 世纪)”的历程。贯穿其中的主线，是对”语言规律能否被精确、形式化地刻画”这一问题的不断探索。理解了这段历史，也就理解了为什么语言学可以用数学公式、自动机理论和逻辑演算来表述——这正是本书的出发点。

2 语言的分类

2.1 分类的两条路径

对人类语言进行分类，主要有两条互补的路径：

- **谱系分类 (Genetic classification)**: 依据语言的历史亲缘关系，把有共同祖先的语言归入同一个语系。
- **类型学分类 (Typological classification)**: 依据语言的结构特征，把语法特征相似的语言归为一类，不论它们是否有亲缘关系。

这两条路径回答了不同的问题：谱系分类回答“语言从哪里来”，类型学分类回答“语言是什么样”。它们互补：同语系的语言通常共享类型特征 (如印欧语多属屈折语)，但类型上相似的语言可以分属不同语系 (如汉语、越南语、泰语都是孤立语却分属不同语系)。

2.2 谱系分类

2.2.1 比较法与同源词

谱系分类的基础是历史比较语言学。通过比较不同语言中的同源词 (cognates)，发现系统性的语音对应规律，可以证明它们同源并重建祖语。同源词的判定标准是“系统的语音对应”，而不是表面相似。例如英语 *father*、德语 *Vater*、拉丁语 *pater*、梵语 *pitṛ* 表面差异很大，但呈现出系统的对应 (p-f-p-p)，由此证明同源。

$$\text{Proto-Language} \xrightarrow{\text{分化}} \{L_1, L_2, \dots, L_n\} \quad (9)$$

2.2.2 谱系树模型与波浪模型

谱系树模型 (树状图) 假设语言从一个祖语“树状”地分化。但语言接触会使分化后的语言重新趋同，因此历史语言学还提出了波浪模型 (Wave Model)：语言变化像波浪一样从创新中心向四周扩散，相邻语言共享某些变化。现代计算语言学用系统发生树 (Phylogenetic tree) 方法，基于词汇、语音、语法数据自动重建语言家族树。

2.2.3 世界主要语系

表 1: 世界主要语系 (使用人口为约数)

语系	代表语言	使用人口 (亿)
印欧语系	英语、西班牙语、印地语、俄语	32
汉藏语系	汉语、藏语、缅甸语	14
尼日尔-刚果语系	斯瓦希里语、约鲁巴语	7
亚非语系	阿拉伯语、希伯来语、豪萨语	5
南岛语系	马来语、他加禄语、马达加斯加语	3.8
达罗毗荼语系	泰米尔语、泰卢固语	2.5
突厥语系	土耳其语、哈萨克语、维吾尔语	2

2.2.4 语系的层次结构

语系的内部有层次结构, 从大到小依次为: 语系 (Family)→ 语族 (Subfamily)→ 语支 (Branch)→ 语言 (Language)→ 方言 (Dialect)。以印欧语系为例:

- **日耳曼语族:** 西日耳曼语支 (英语、德语、荷兰语)、北日耳曼语支 (瑞典语、挪威语、丹麦语)
- **罗曼语族:** 法语、西班牙语、意大利语、葡萄牙语、罗马尼亚语
- **斯拉夫语族:** 俄语、波兰语、捷克语、塞尔维亚语
- **印度-伊朗语族:** 印地语、乌尔都语、波斯语、孟加拉语

值得注意的是, 语言与方言的界限往往是社会政治的而非纯语言学的: ”一种语言就是拥有一支军队的方言” 这一说法形象地说明了这一点。汉语的各个”方言”(如粤语、闽南语、吴语) 彼此不能通话, 差异程度堪比欧洲的不同语言, 但因共享统一的文字与民族认同而被归为”汉语的方言”。

2.3 类型学分类: 按词法类型

语言按构词方式可分为四大类型, 这是最经典的类型学分类:

2.3.1 孤立语 (Isolating)

孤立语中, 词几乎没有形态变化, 语法关系主要靠语序和虚词表达。词、语素、音节之间基本一一对应:

例: 汉语”我吃饭” 每个字 = 一个语素 = 一个词 (10)

汉语、越南语、泰语、约鲁巴语都是典型的孤立语。孤立语没有”复数词缀””格词缀”这类屈折变化:”我吃饭”和”他吃饭”中”吃”不因主语的人称而变形。

2.3.2 黏着语 (Agglutinative)

黏着语的词干后逐个添加词缀,每个词缀只表达一种语法信息,词缀边界清晰,可以机械地堆叠:

例:土耳其语 *ev-ler-im-den* = 房子-复数-我的-从 (11)

ev-ler-im-den 可以拆解为词干 *ev*(房子)、复数词缀 *-ler*、第一人称属有词缀 *-im*(我的)、离格词缀 *-den*(从)。每个词缀只有一个意义,边界一目了然。日语、韩语、土耳其语、斯瓦希里语、匈牙利语都是黏着语。

2.3.3 屈折语 (Fusional)

屈折语中,一个词缀可能同时携带多种语法信息,词缀与意义之间是多对多的融合关系:

例:拉丁语 *amo* = 我爱 (一个词尾 *-o* 同时表示第一人称、单数、现在时、陈述语气) (12)

屈折语的形态与语序有”冗余”:拉丁语中 *puella amat puerum*(女孩爱男孩)即使换语序也基本可解,因为格词尾标明了谁爱谁。俄语、德语、西班牙语、阿拉伯语、古典希腊语都是典型的屈折语。

2.3.4 多式综合语 (Polysynthetic)

多式综合语(也称复综语)的一个动词词中可以包含主语、宾语、副词、时态等几乎所有成分,一个词就可以表达一个完整的句子:

例:因纽特语 *tusaatsiarunnangittualuujunga* = 我听不太清 (13)

北美原住民语言(如莫霍克语)、西伯利亚的楚科奇语、澳大利亚的许多原住民语言都是多式综合语。

表 2: 形态类型对比

特征	孤立语	黏着语	屈折语	多式综合语
语素/词比	约 1:1	高	中	极高
词缀边界	无词缀	清晰	融合	高度融合
代表语言	汉语、越南语	日语、土耳其语	德语、俄语	因纽特语、莫霍克语
语法手段	语序、虚词	词缀堆叠	词尾变化	词内整合

需要强调的是，这四类只是理想类型。真实语言几乎都混合了多种类型：英语在形态上是孤立的（几乎没有格变化），但保留了屈折遗迹（-s 复数、-ed 过去时、不规则动词 *go/went*）。因此类型学分类描述的是语言的主导倾向，而不是非此即彼的标签。

2.4 类型学分类：按句法类型

2.4.1 基本语序

按句中主语 (S)、动词 (V)、宾语 (O) 的相对顺序，世界语言可分为若干类型：

表 3: 基本语序类型及其分布 (基于 WALS 数据库)

语序	比例	代表语言
SVO	42%	英语、汉语、法语、俄语
SOV	45%	日语、土耳其语、藏语、印地语
VSO	9%	阿拉伯语、威尔士语、爱尔兰语
VOS	3%	马尔加什语、菲吉语
OVS / OSV	< 1%	罕见 (如希克斯卡亚纳语)

值得注意的是，SOV(主语-宾语-动词) 和 SVO(主语-动词-宾语) 合计占 87%，而 OVS/OSV 几乎不存在。这不是巧合，而是反映了语言对人类最自然的信息组织方式 (施事在前)。

2.4.2 类型学相关性：头参数

语序不是孤立的，它与介词类型、名词-形容词顺序等”打包”出现，形成类型学上的相关性 (相关词序共性)。核心规律是中心词 (*head*) 参数：

- 中心词在前 (Head-initial): 使用前置词 (*in the house*)，SVO 语序
- 中心词在后 (Head-final): 使用后置词 (家の中 = 家之中)，SOV 语序

$$\forall L : \text{Head-initial}(L) \leftrightarrow \text{Prep}(L) \quad (14)$$

日语”家の中”(house-of-in) 中，属格标记”の”位于名词之后，是典型的中心词在后 (后置词) 类型；英语 *in the house* 则反之。汉语是少见的例外：基本语序为 SVO(中心词在前)，却使用后置词式的结构 (”桌子上”)，同时拥有前置词 (”在桌上”)。这种”混合”说明类型学相关是统计规律而非铁律。

2.5 形式化类型学特征

语言类型学可以形式化地表述为语言共性 (Universals)。格林伯格 (Greenberg) 提出了大量蕴含式共性, 可用一阶逻辑表示:

$$\forall L \in \text{Languages} : \text{VSO}(L) \rightarrow \text{Prep}(L) \quad (15)$$

格林伯格的经典共性包括:

- 若语言以 VSO 为基本语序, 则使用前置词 (格林伯格共性 3)
- 若语言以 SOV 为基本语序, 则几乎所有属格都位于名词之前
- 若语言是主格-宾格语言, 则宾语在动词之后或之前与语序相关

形式化的共性刻画允许我们定义类型空间:

$$\text{语言类型} = \prod_i \{\text{特征 } F_i \text{ 的取值}\} \quad (16)$$

每一种自然语言都可以表示成一组特征取值构成的“向量”, 类型学的研究就是在该空间中寻找聚类与规律。

2.5.1 蕴含层级与标记性

格林伯格共性常常构成蕴含层级 (implicational hierarchy)。以格系统为例:

$$\text{主格} \prec \text{宾格/通格} \prec \text{与格} \prec \text{属格} \prec \text{方位格} \prec \dots \quad (17)$$

层级意味着: 一种语言若具有层级中靠后的格, 则必然也具有其前面的所有格。这种蕴含关系与标记性 (markedness) 理论一致: 层级靠后的格是“有标记”(更特殊) 的范畴。

2.6 语言接触与混合

2.6.1 语言联盟 (Sprachbund)

地理上相邻但无亲缘关系的语言, 长期接触后会在结构上趋同, 形成语言联盟。最著名的例子是巴尔干语言联盟: 保加利亚语、罗马尼亚语、阿尔巴尼亚语、马其顿语分属不同语族, 却共享“后置定冠词”“复合将来时”“属格/与格合并”等特征。语言联盟可以形式化为:

$$L_1, L_2 \xrightarrow{\text{长期接触}} \text{共享特征集合 } F \quad (18)$$

汉语与周边语言的接触 (如日语、朝鲜语、越南语借入大量汉语词汇, 粤语、闽南语向东南亚语言传播) 是语言接触影响类型面貌的又一例证。

2.6.2 皮钦语与克里奥尔语

- **皮钦语 (Pidgin)**: 在没有共同语言的人群交流中产生的简化混合语，语法简单、词汇有限，没有母语者。
- **克里奥尔语 (Creole)**: 皮钦语成为下一代儿童的母语后，语法迅速复杂化，形成完整的自然语言。

$$\text{Pidgin}(L_1, L_2) \xrightarrow{\text{母语化}} \text{Creole} \quad (19)$$

克里奥尔语的形成过程是“语言的出生”，在语言学上意义重大：它证明人类儿童在输入极不充分的条件下（皮钦语语法高度简化）仍能生成出语法完整的语言——这成为刺激贫乏论与普遍语法的天然证据。海地克里奥尔语（以法语为基础）是有数百万使用者的克里奥尔语。

2.7 语言演化模型

语言的演化和生物进化类似，可以用数学模型刻画。语言特征的使用比例随世代变化，最简单的模型是逻辑斯蒂增长模型：

$$\frac{dP}{dt} = \mu \cdot P \cdot (1 - P) \quad (20)$$

其中 P 是某语言特征的使用比例， μ 是变化速率参数。

更完整的模型把语言变化看作复制者动态 (Replicator dynamics)：说话者学习语言时以一定概率复制母语者的特征，同时存在创新与选择压力。词汇替代率可以用斯瓦德什核心词表 (Swadesh list) 和词汇统计年代学 (Glottochronology) 来估计：

$$t = \frac{\ln(c/C)}{\ln(\lambda)} \quad (21)$$

其中 c 是同源词保留比例， C 是初始比例， λ 是词汇保留率常数。现代计算类型学则直接用贝叶斯系统发生学方法，在语系树与时间尺度上同时估计音变、词变与类型演化的速率。

2.8 本章小结

语言分类的两条路径——谱系分类 (历史亲缘) 与类型学分类 (结构特征)——分别从“源流”与“面貌”两个维度刻画语言。语系揭示语言的血缘关系，类型揭示语言的内部结构规律。类型学特征不是孤立的，而是以蕴含层级、中心词参数等方式相互关联。这些关联为最后一章“不同语言之间的差异”提供了系统的坐标：任何两种语言，都可以在语音、词法、句法、文字等维度上定位其差异。语言接触则提醒我们，语言不是封闭系统，“差异”本身也在不断演变。

3 形式化语言基础

3.1 形式语言理论概述

形式语言理论是计算机科学和语言学的交叉领域，由诺姆·乔姆斯基在 1956 年奠基。它提供了一套精确的数学工具来描述语言的句法结构。这里所说的“语言”不仅指自然语言，也包括编程语言、正则表达式、DNA 序列等一切由符号构成的集合。

形式语言理论的核心思想：一个语言不过是某个字母表上的字符串集合，而文法 (grammar) 是生成这个集合的有限规则系统。它把“什么是合法的句子”这个语言学问题转化为“集合论与自动机”的数学问题：

$$\text{语言} \subseteq \Sigma^* \quad \text{其中} \Sigma \text{ 是字母表} \quad (22)$$

3.2 字母表与字符串

3.2.1 基本定义

定义 3.1 (字母表). 字母表 Σ 是一个有限的非空符号集合。

例子 3.1.

$$\Sigma_{\text{英语}} = \{a, b, c, \dots, z\}$$

$$\Sigma_{\text{二进制}} = \{0, 1\}$$

$$\Sigma_{\text{DNA}} = \{A, C, G, T\}$$

定义 3.2 (字符串). 字符串 w 是字母表 Σ 中符号的有限序列。

3.2.2 字符串的基本运算

- $|w|$: 字符串 w 的长度
- ϵ : 空字符串, $|\epsilon| = 0$
- uv : 字符串 u 和 v 的连接 (concatenation)
- w^R : 字符串 w 的反转 (reverse)
- w^k : 字符串 w 的 k 次重复
- Σ^* : Σ 上所有字符串的集合 (包括 ϵ)
- Σ^+ : Σ 上所有非空字符串的集合

3.2.3 语言作为集合

定义 3.3 (语言). Σ 上的一个语言 L 是 Σ^* 的任意子集: $L \subseteq \Sigma^*$ 。

语言可以非常小 (空集 $\emptyset$ 、单个字符串 $\{ab\}$) 也可以无限大 (如“所有以 a 开头、 b 结尾的字符串” $\{awb : w \in \Sigma^*\}$)。关键问题是: 一个无限语言能否用有限的方式描述? 这正是文法和自动机要回答的问题。

语言之间有基本的集合运算: 并、交、差、补、连接、Kleene 星:

$$L_1 \cdot L_2 = \{uv \mid u \in L_1, v \in L_2\}, \quad L^* = \bigcup_{k \geq 0} L^k \quad (23)$$

3.3 文法与乔姆斯基层级

3.3.1 形式文法定义

定义 3.4 (短语结构文法). 文法 G 是一个四元组:

$$G = \langle V_N, V_T, P, S \rangle \quad (24)$$

其中:

- V_N : 非终结符 (*Non-terminal*) 集合, 代表语法范畴 (如 S 、 NP 、 VP)
- V_T : 终结符 (*Terminal*) 集合, 代表实际词/符号, $V_N \cap V_T = \emptyset$
- P : 产生式 (*Production*) 规则集合, 形如 $\alpha \rightarrow \beta$
- $S \in V_N$: 起始符号 (*Start symbol*)

文法生成语言的过程是: 从起始符 S 出发, 反复应用产生式, 直到所有非终结符都被替换为终结符。记 $\Rightarrow$ 为“一步推导”, 则

$$L(G) = \{w \in V_T^* \mid S \Rightarrow^* w\} \quad (25)$$

其中 $\Rightarrow^*$ 表示零步或多步推导。一个语言若存在某个文法生成它, 就称该语言是递归可枚举的 (这里指 0 型)。

3.3.2 乔姆斯基层级

根据产生式形式的限制, 文法可以分为四个层次, 每一层生成的语言严格包含下一层:

表 4: 乔姆斯基层级

类型	文法	产生式形式	自动机
0	无限制文法	$\alpha \rightarrow \beta$	图灵机
1	上下文有关	$\alpha A \beta \rightarrow \alpha \gamma \beta$	线性有界自动机
2	上下文无关	$A \rightarrow \gamma$	下推自动机
3	正则	$A \rightarrow aB$ 或 $A \rightarrow a$	有限状态自动机

$$\mathcal{L}_0 \supsetneq \mathcal{L}_1 \supsetneq \mathcal{L}_2 \supsetneq \mathcal{L}_3 \quad (26)$$

其中 $\mathcal{L}_i$ 表示 i 型文法生成的语言类。层级关系是严格的： $\{a^n b^n\}$ 是上下文无关但非正则的； $\{a^n b^n c^n\}$ 是上下文有关但非上下文无关的。

3.4 正则语言 (Type-3)

3.4.1 正则表达式

正则表达式 (Regular Expression) 是最直观地描述正则语言的方式，其递归定义如下：

$$\begin{aligned} \emptyset & \text{ 是正则表达式 (表示空语言)} \\ \epsilon & \text{ 是正则表达式 (表示 } \{\epsilon\} \text{)} \\ a \in \Sigma & \text{ 是正则表达式 (表示 } \{a\} \text{)} \\ \text{若 } r, s & \text{ 是正则表达式, 则 } (r|s), (rs), (r^*) \text{ 也是} \end{aligned} \quad (27)$$

这里 $r|s$ 是并、 rs 是连接、 r^* 是 Kleene 星 (零次或多次重复)。语法糖包括： $r^+ = rr^*$ (一次以上)、 $r? = (r|\epsilon)$ (零次或一次)、 $[a - z]$ 表示区间。

3.4.2 有限状态自动机 (FSA)

定义 3.5 (DFA). 确定性有限自动机 $M = \langle Q, \Sigma, \delta, q_0, F \rangle$

- Q : 有限状态集合
- Σ : 输入字母表
- $\delta: Q \times \Sigma \rightarrow Q$: 转移函数
- $q_0 \in Q$: 起始状态
- $F \subseteq Q$: 接受状态集合

DFA 从 q_0 出发, 逐个读入输入符号并转移状态。若读完整个输入后停在 F 中的某个状态, 则接受该字符串; 否则拒绝。DFA 接受的语言记作 $L(M)$ 。

定理 3.1 (克莱因定理). 正则语言类 = 正则表达式可描述的语言类 = DFA/NFA 可接受的语言类。

例子 3.2 (识别英语复数后缀).

$$\text{正则表达式: } [a-z]^*(s|es|ies) \quad (28)$$

DFA 能识别“字符串由小写字母组成且以 s 、 es 或 ies 结尾”。有限状态自动机的局限也在于此: 它没有记忆, 无法统计括号匹配的嵌套层数, 因此不能识别形如 $a^n b^n$ 的语言。

正则语言的封闭性质使其在计算上极其便利: 正则语言对并、交、差、补、反转、同态都是封闭的, 且可判定性 (成员问题、空性、等价性) 都有高效算法。这就是为什么正则表达式被广泛应用于文本搜索、词法分析 (如编译器的 lex) 和 NLP 的词形还原。

3.5 上下文无关文法 (Type-2)

3.5.1 CFG 定义

上下文无关文法的产生式形式为:

$$A \rightarrow \alpha \quad \text{其中 } A \in V_N, \alpha \in (V_N \cup V_T)^* \quad (29)$$

“上下文无关”的意思是: 替换一个非终结符时, 不依赖于它左右两边的上下文。这使 CFG 非常适合描述语言的递归嵌套结构——自然语言和编程语言中最常见的结构。


例子 3.3 (回文语言). $L = \{w \in \{a, b\}^* \mid w = w^R\}$ 是上下文无关的:

$$S \rightarrow aSa \mid bSb \mid a \mid b \mid \epsilon \quad (30)$$

这个语言不是正则的: 识别它需要记住已经读入的内容, 而 DFA 没有记忆。

3.5.2 句法树

CFG 的重要性质是: 一个推导过程对应一棵句法树 (Parse Tree, 也称推导树), 树根是 S , 叶节点是终结符。句法树显式刻画了句子的层次结构, 这正是自然语言句法分析的目标:



3.5.3 歧义与二义性文法

同一个句子可以对应多棵句法树，称为结构歧义 (structural ambiguity)。经典例子：

"I saw the man with the telescope" (31)

可以是“我用望远镜看那个人”(with 修饰 *saw*)，也可以是“我看见那个拿望远镜的人”(with 修饰 *man*)。两种解读对应两棵不同的句法树。一个文法若对某个句子能产生多棵句法树，就称为二义性文法。存在无法消除二义性的上下文无关语言，即固有歧义语言。

3.5.4 范式

- **乔姆斯基范式 (CNF)**: 每条产生式形如 $A \rightarrow BC$ 或 $A \rightarrow a$ 。任何 CFG 都可以等量地 (语言不变) 转化为 CNF，且任何不产生 ϵ 的 CFG 都可以。CNF 的最大价值在于：它把推导树的内部节点统一为“两分叉”，使得 CYK 算法 (动态规划句法分析) 可以直接应用。
- **格雷巴赫范式 (GNF)**: 产生式形如 $A \rightarrow a\alpha$ ，其中 $\alpha \in V_N^*$ 。GNF 保证每一步都吃掉一个终结符，便于构造下推自动机。

3.6 下推自动机与上下文无关语言

上下文无关语言对应下推自动机 (PDA)：在有限状态的基础上增加一个栈 (stack)。栈提供了“无限记忆”，但只能以后进先出方式访问。正是这个栈使得 PDA 能识别

$a^n b^n$ (读 a 时压栈, 读 b 时弹栈)。

定理 3.2. L 是上下文无关语言当且仅当存在一个下推自动机 M 使得 $L = L(M)$ 。

3.7 上下文有关文法 (Type-1)

产生式形式:

$$\alpha A \beta \rightarrow \alpha \gamma \beta \quad (32)$$

其中 $A \in V_N$, $\alpha, \beta, \gamma \in (V_N \cup V_T)^*$, 且 $\gamma \neq \epsilon$ 。

这里的限制是: A 只有在左右分别是 α 和 β 时才能被替换为 γ , 即替换依赖上下文。这种“上下文敏感性”使上下文有关文法能表达非上下文无关的结构。

例子 3.4. 语言 $\{a^n b^n c^n : n \geq 1\}$ 是上下文有关的。上下文无关文法无法识别它, 因为 a 、 b 、 c 的个数需要同步约束; 而上下文有关文法可以让每个 a 在与某个 b 、某个 c 配对后一起替换:

$$S \rightarrow aSBC \mid aBC, \quad CB \rightarrow BC, \quad aB \rightarrow ab, \quad bB \rightarrow bb, \quad bC \rightarrow bc, \quad cC \rightarrow cc \quad (33)$$

上下文有关文法对应线性有界自动机 (LBA), 即使用量受限的图灵机 (磁带长度与输入长度成正比)。

3.8 形式语言与自然语言

3.8.1 自然语言的复杂度

自然语言的句法结构位于乔姆斯基层级的哪一层? 这是形式语言学的基本问题之一。答案是: 自然语言超出上下文无关文法的能力, 但通常只需温和上下文有关 (Mildly context-sensitive) 的层级:

- **跨串依赖 (Cross-serial dependencies):** 瑞士德语和荷兰语中的交叉依赖结构。在“我让他叫约翰帮忙打扫房间”这类结构中, 动词与宾语交叉对应, 无法用 CFG 表达。
- **温和上下文有关 (Mildly context-sensitive):** 介于 CFG 与上下文有关文法之间的层级, 能表达交叉依赖但保持可解析性。
- **树邻接文法 (TAG)、组合范畴文法 (CCG):** 是温和上下文有关的代表性形式体系, 被广泛用于计算句法学。

$$\mathcal{L}_{CFG} \subsetneq \mathcal{L}_{TAG} \subsetneq \mathcal{L}_{MCS} \subseteq \mathcal{L}_1 \quad (34)$$

3.8.2 依存语法

短语结构文法描述的是“成分层级”，而依存语法 (Dependency Grammar) 描述词与词之间的二元关系：

$$\text{依存关系} = \{(h, d, r) \mid h, d \in W, r \in R\} \quad (35)$$

其中 h 是中心词， d 是从属词， r 是关系类型 (如 *nsubj*、*dobj*)。依存结构更接近语义关系，且与语序相对独立，因此跨语言的适用性很强——这也为最后一章“不同语言的差异”提供了统一的比较工具：不同语言在依存关系上高度相似，差异主要体现在语序和形态。

3.9 形式语义基础

3.9.1 Lambda 演算

形式语言理论主要关心句法 (什么是合法句子)，而形式语义学要回答“句子是什么意思”。Lambda 演算提供了组合意义的形式工具：

$$\begin{aligned} \text{变量: } & x, y, z, \dots \\ \text{抽象: } & \lambda x.M \quad (\text{函数, 把 } x \text{ 映射到 } M) \\ \text{应用: } & (M \ N) \quad (\text{把函数 } M \text{ 应用到 } N) \end{aligned} \quad (36)$$

例子 3.5. “*runs*” 的语义表示：

$$\llbracket \text{runs} \rrbracket = \lambda x.run(x) \quad (37)$$

它表示“谓词 *run* 对主体 x 成立”这个函数。组合语义的基本思想是：一个句子的意义由各成分的意义组合而成，Lambda 演算使这种组合可以机械地进行。

3.10 本章小结

形式语言理论为语言学提供了精确的“标尺”：乔姆斯基层级刻画了语言结构复杂度的层级，正则语言对应最“简单”的结构 (无递归记忆)，上下文无关文法对应嵌套结构 (自然语言句法的核心层级)，温和上下文有关覆盖了自然语言的完整复杂度。文法则架起了“有限规则”与“无限语言”之间的桥梁——这正回答了语言习得中的核心悖论：人类如何用有限的头脑掌握无限的语言能力。下一章将从词出发，考察词的内部结构 (形态学)，那里同样充满形式化的规律。

4 词法 (形态学)

4.1 形态学概述

形态学 (Morphology) 研究词的内部结构和构词规则。词不是不可分割的意义单元——大多数词都可以分解为更小的、携带意义的构件。

定义 4.1 (语素). 语素 (*Morpheme*) 是最小的有意义的语言单位, 不能再继续分割为更小的有意义的部件。

例如 *unhappiness* 可以分解为 *un* + *happi* + *ness* 三个语素, 而 *cat* 虽然可分割为语音 /kæt/, 但那些音段本身没有意义, 因此 *cat* 是一个语素。

形态学研究的两大任务:

- **屈折 (Inflection):** 同一个”词”的不同语法形式 (如 *walk/walked/walking*)
- **派生 (Derivation):** 由已有词构成新词 (*happy* → *happiness*)

形态学还提供了一个重要的类型学参数: 语素与词的比率——这个比率决定了语言的形态类型 (孤立语/黏着语/屈折语/多式综合语), 是最后一章跨语言比较的核心维度之一。

4.2 语素类型

4.2.1 按独立性

- **自由语素 (Free morpheme):** 可以独立成词, 单独使用

例: *cat*, *run*, *happy*, 桌子 (38)

- **黏着语素 (Bound morpheme):** 必须依附于其他语素, 不能单独成词

例: *-s*, *-ed*, *un-*, *-ness*, 汉语中的”们”在单独出现时无意义 (39)

4.2.2 按功能

- **词根 (Root):** 词的核心意义, 去掉所有词缀后剩下的部分
- **词干 (Stem):** 可以添加屈折词缀的形式 (可能是”词根 + 派生词缀”)
- **词缀 (Affix):** 附着在词根/词干上的黏着语素, 按位置分类:

– 前缀 (Prefix): *un-*, *re-*, *pre-* (位于词根之前)

- 后缀 (Suffix): -s, -ed, -ing, -ness (位于词根之后, 世界上最多见)
- 中缀 (Infix): 插入词根内部, 较少见, 如他加禄语 *-um-*
- 环缀 (Circumfix): 同时加在词根前后, 如德语过去分词 *ge-mach-t*
- 异干法 (Suppletion): 完全不同形式的语素交替, 如 *go/went*

4.3 屈折 (Inflection)

4.3.1 屈折的性质

屈折不改变词的词汇意义和词类, 只添加语法信息 (如数、格、时态), 并且一个屈折范畴是强制性的——英语名词一旦用作复数就必须加 *-s*, 不能省略:

$$\text{walk} \xrightarrow{+\text{过去时}} \text{walked} \quad (40)$$

4.3.2 屈折范畴

- 数 (Number): *cat/cats*, 汉语“猫/猫们”(有限制, 只用于人)
- 格 (Case): *he/him/his* ——英语保留了主格/宾格/属格残迹
- 时态 (Tense): *walk/walked* ——时间定位
- 体 (Aspect): *walk/walking* ——动作的内部时间结构 (进行/完成)
- 人称 (Person): *am/are/is*
- 性 (Gender): 德语 *der/die/das*, 法语 *le/la* ——语法性不一定是自然性别
- 语气 (Mood): 陈述/虚拟/祈使 (英语 subjunctive 残存于 “I suggest that he *be* here”)
- 态 (Voice): 主动/被动 (*was eaten*)
- 级 (Degree): *tall/taller/tallest* (形容词屈折)

4.3.3 屈折的跨语言差异

屈折范畴在不同语言中的分布差异极大, 这是跨语言比较的重点之一:

- 汉语几乎无屈折, 时态靠时间词和体助词 (“了” “着” “过”) 表达
- 英语保留了少量屈折 (复数 *-s*、过去时 *-ed*、第三人称 *-s*), 但比德语、俄语少得多
- 俄语名词有 6 个格, 形容词有 24 种形式 (数 $\times$ 性 $\times$ 格)

- 日语、韩语动词有人称无关、但极复杂的敬体/简体系统
- 许多语言名词没有”格”，但有的语言有几十种格 (如芬兰语名词有 15 个格)

4.4 派生 (Derivation)

4.4.1 派生的性质

派生通过加词缀创造新词，可以改变词类或改变核心意义，且派生是选择性的 (不一定能派生所有同类词)：

happy (adj.) $\xrightarrow{+ness}$ happiness (n.) (41)

write (v.) $\xrightarrow{+re-}$ rewrite (v.) (42)

kind (adj.) $\xrightarrow{+un-}$ unkind (adj.) (43)

teach (v.) $\xrightarrow{+er}$ teacher (n.) (44)

4.4.2 派生与屈折的对比

表 5: 屈折与派生的区别		
特征	屈折	派生
是否创造新词	否	是
是否改变词类	否	常改变
强制性	是	否
与语法环境相关	是	否
产出顺序	在派生之后	在屈折之前

这一顺序 (派生在内、屈折在外) 是语言普遍存在的规律，可形式化为词缀顺序约束 (见下文)。

4.5 构词方式总览

构词方式 (Word Formation) 研究新词是如何被创造出来的。除了前面介绍的屈折与派生，语言学家还归纳出大量其他构词方式，大致可分为”词内新造”与”外来借入”两大类，词内新造又分为组合型、缩短型与转换/语义型。下表给出全貌：

表 6: 构词方式一览

类别	方式	机制	例
组合型	复合	词根 + 词根	火车、blackboard
组合型	重叠	重复语素	人人、anak-anak
组合型	拟声词	语音模拟声音	buzz、叮当
组合型	专名转化	专名转为通名	sandwich、牛顿
缩短型	截短	删去词的一部分	lab、bus
缩短型	逆构词	删去误认的词缀	edit←editor
缩短型	缩写	取各词首字母	radar、FBI
缩短型	混成	两词部分融合	brunch、smog
转换/语义	转类	词形不变换词类	email(v.)
转换/语义	语义造词	词义引申出新义	web→ 互联网
转换/语义	比喻造词	隐喻/转喻造词	瓶颈、bug
借入	音译	借音不借形	沙发 (sofa)
借入	意译	译义造新词	电脑 (computer)
借入	仿译	逐语素对应翻译	热狗 (hot dog)
借入	音义兼译	音义兼顾	可口可乐
借入	借形	借字形不借音	电话 (自日语)
借入	语义借用	旧词借新义项	病毒 (计算机)

下面分组详述。

4.6 组合型构词

组合型构词把已有的词根或语素“拼”在一起，是汉语、英语、日语、德语中最能产的构词方式。

4.6.1 复合 (Compounding)

复合 (Compounding) 是两个或以上的词根直接组合成新词的过程，产物叫复合词 (compound)。它是世界上绝大多数语言都具备的构词方式。

表 7: 复合词的内部结构类型 (汉语为例)

类型	结构关系	例子
并列复合	两成分地位平等	山水、黑白、声音
偏正复合	前修饰、后中心	火车、黑板、白菜
动宾复合	动词 + 宾语	开门、司令、起草
动补复合	动词 + 补语	提高、证明、扩大
主谓复合	主语 + 谓语	地震、心疼、民主

英语名词复合词最常见的是“修饰语 + 中心语”结构 (football = foot+ball, 中心在“球”), 但词性组合很多样: 名词 + 名词 (rainbow)、形容词 + 名词 (blackboard)、动词 + 名词 (swimming pool) 等。

复合词与短语的区别在英语中可以用重音来检验: 复合词重音落在第一成分 (black-board 黑板), 而短语重音落在第二成分 (black board 黑色的板)。汉语中复合词与短语的界限较模糊: “火车”“黑板”已经完全词汇化, 而“大门”“红车”既可看作复合词也可看作短语。

复合是汉语最能产、最古老的构词方式之一, 现代汉语新词绝大多数是复合词: 手机、高铁、网红、外卖。德语也以复合著称, 可以造出很长的复合词 (Rindfleischetikettierungsüberwachungsaufgabenübertragungsgesetz, 牛肉标签监管任务转移法); 英语同样用复合不断造新词 (firewall、lockdown、greenhouse)。

4.6.2 重叠 (Reduplication)

重叠 (Reduplication) 通过重复语素或音节构成新词形, 可以是全部重复, 也可以是部分重复:

表 8: 重叠的类型与功能

类型	方式	例子
完全重叠	整个词根重复	人人、日日、anak-anak(孩子们)
部分重叠	只重复部分音节	他加禄语、拉丁语完成时 (cecini)
变韵重叠	重叠时元音变化	chit-chat、ping-pong、zigzag

重叠的功能因语言而异, 非常多样:

- 名词: 表示复数或“每一”——印尼语 anak-anak(孩子们)、汉语“人人”(每个人)、“家家”

- 动词：表示尝试或随意——汉语“看看”“想想”“试试”
- 形容词：表示程度加深或生动——汉语“高高”“红红的”“漂漂亮亮”
- 量词：表示“逐个”——汉语“一个个”“一天天”
- 拟声拟态：摹写声音或状态——日语“わくわく”(心怦怦)、“ざあざあ”(雨声)

汉语、印尼语、马来语、日语是重叠极丰富的语言；英语重叠较少，主要用于拟声 (ding-dong) 和口语叠词 (tip-top、hush-hush)。

4.6.3 拟声词 (Onomatopoeia)

拟声词 (Onomatopoeia) 用语音模拟事物声音，是“以声造词”。

- 直接拟声：模拟自然界或动物的声音。英语 buzz(嗡嗡)、meow(喵)、clap(啪)、cuckoo(布谷)，汉语“叮当”“哗啦”“喵”“汪汪”。
- 拟声拟态词 (ideophone)：不仅模拟声音，还摹写形状、状态、心情。日语拟声拟态词极其丰富，数量达数千个，如“わくわく”(心怦怦跳)、“きらきら”(闪闪发光)、“ぐっすり”(熟睡)；韩语、西非语言也有庞大的拟态词系统。

拟声词具有高度的语言特异性：同一种声音在不同语言中“听感”截然不同，因为每种语言都用自己有限的音位系统去模拟：

表 9: 同一声音在不同语言中的拟声差异

声音	英语	日语	汉语
狗叫	woof / bark	ワンワン (wan-wan)	汪汪 (wāngwāng)
鸡叫	cock-a-doodle-doo	コケコッコー (kokekōkō)	喔喔喔 (wōwōwō)
猫叫	meow	ニャー (nyā)	喵 (miāo)

4.6.4 专名转化 (Eponym)

专名转化 (Eponym) 把专有名词——人名、地名、品牌名、文学人物——转用为普通名词：

表 10: 专名转化的来源

来源	机制	例子
人名	以发明者或人物命名	sandwich(三明治)、volt(伏特)、牛顿、瓦特
地名	以产地命名	champagne(香槟)、denim(牛仔布)、china(瓷器)
品牌	品牌名泛化	kleenex(纸巾)、xerox(复印)、百度一下
神话文学	以文学人物命名	quixotic(唐吉珂德式)、阿斗

品牌名”普通化”(genericide) 是专名转化最活跃的类型: 品牌一旦成为某类商品的通称, 商标就失去专有性。kleenex 原是面巾纸品牌, 现泛指纸巾; xerox 原是复印机品牌, 现作动词”复印”。汉语”百度”也正在经历同样的转化: ”百度一下”就是”搜索一下”。历史人物”阿斗”(扶不起的阿斗)、”雷锋”(助人为乐者) 则是人物转义的典型。

4.7 缩短型构词

缩短型构词从已有的长词或短语中删减材料, 形成更短的新形式, 追求简便。

4.7.1 截短 (Clipping)

截短 (Clipping) 删去原词的一部分, 词义与词类不变, 只是形式变短:

表 11: 截短的部位

类型	方式	例子
保留词首	删去词尾	exam(examination)、lab(laboratory)、phone(telephone)
保留词尾	删去词首	bus(omnibus)、phone(telephone)
保留中部	删去首尾	flu(influenza)、fridge(refrigerator)

截短词通常带口语、亲切的色彩, 如 *prof* (professor)、*gym* (gymnasium)、*math* (mathematics)、*tech* (technology)。

人名也常被截短作昵称, 如 *Jen* (Jennifer)、*Pat* (Patricia)。有些截短词完全取代了原词, 如 *bus* 已很少有人知道它来自 *omnibus*。

4.7.2 逆构词 (Back-formation)

逆构词 (Back-formation) 通过删去一个被误认为词缀的部分, 逆向造出”更简单”的词。其关键在于词形的历史顺序: 先有长形式, 后逆推出短形式。

表 12: 逆构词例子

新词	来源	机制
edit(编辑)	editor	误以为 -er 是”施事者”后缀
swindle(诈骗)	swindler	同上
babysit(照看婴儿)	babysitter	删去 -er
donate(捐赠)	donation	误以为 -ion 是名词化后缀
pea(豌豆)	pease	误以为 -s 是复数后缀

逆构词与截短的区别：截短只是缩短形式、不改变词类与构词结构 (lab 仍是名词)；逆构词则改变词类或结构 (editor 名词 → edit 动词)。逆构词反映说者对构词的”再分析”——把不存在的词缀去掉，类比地推出新词，甚至 laser 也被戏谑地逆构为动词 to lase(发射激光)。

4.7.3 缩写 (Abbreviation)

缩写从短语中取首字母 (或首音节) 形成新词，是科技与网络时代最活跃的构词方式：

表 13: 缩写的类型

类型	读音	例子	来源
首字母缩略词 (Acronym)	按单词拼读	radar、laser、NATO、scuba	各词首字母
首字母缩写 (Initialism)	按字母逐个读	FBI、TV、UN、IBM	各词首字母
音节缩略/简称	取首音节	北外、央视、スマホ、東大	首音节/简称

- **Acronym(按词拼读)**: radar = RAdio Detection And Ranging、laser = Light Amplification by Stimulated Emission of Radiation、NATO = North Atlantic Treaty Organization、scuba = self-contained underwater breathing apparatus。
- **Initialism(按字母读)**: FBI、TV、UN、IBM、USA。
- **音节缩略/简称**: 汉语”北外”(北京外国语大学)、”央视”(中央电视台)；日语”スマホ”(スマートフォン, smartphone)、”東大”(東京大学)；俄语也有大量音节缩略词。

4.7.4 混成 (Blending)

混成 (Blending) 把两个词的部分音节”嫁接”成一个新词, 又称拼合词 (portmanteau)。与复合不同, 混成通常只保留源词的部分音节:

表 14: 混成的结构

结构	例子	来源
前词首 + 后词尾	brunch(早午餐)	breakfast+lunch
前词首 + 后词首	modem(调制解调器)	modulator+demodulator
重叠混成 (音相近)	guesstimate(毛估)、spork(勺叉)	guess+estimate、spoon+fork

其他经典混成: smog = smoke+fog(烟雾)、motel = motor+hotel(汽车旅馆)、sitcom = situation+comedy(情景喜剧)、telethon = television+marathon(电视马拉松)。”portmanteau”一词来自刘易斯·卡罗尔在《爱丽丝镜中奇遇》中造的词 chortle = chuckle+snort。

混成在英语中最为活跃; 汉语因每个字都是独立语素, 混成较少见, 口语缩合 (如”高大上”) 更接近简称而非典型混成, 日语中也较少见。

4.8 词类转换与语义构词

4.8.1 转类 (Conversion)

转类 (Conversion) 不改变词形、只改变词类, 因此又称”零派生”(zero derivation)。它是英语最活跃的构词方式之一——英语屈折很弱, 词本身几乎不带词类标记:

表 15: 转类的方向

转换方向	例子	说明
名词 → 动词	email(v.)、google(v.)、access(v.)	网络时代尤为典型
动词 → 名词	walk(n.)、run(n.)、guess(n.)	动作转指事件/结果
形容词 → 动词	empty(v.)、clean(v.)、dry(v.)	使然动词
形容词 → 名词	the rich、the poor、original	指人/指事物

汉语的转类表现为”兼类”与”词类活用”: 名词”雷锋”可临时用作形容词 (”他很雷锋”); ”百度”由名词转作动词 (”百度一下”)。传统语法学界长期争论”汉语到底有没有词类”, 正是因为汉语词几乎没有形态标记, 同一个词形可以出现在多种语法位置。

4.8.2 语义造词: 词义变化 (Semantic Change)

语义造词不改变词形，而是通过词义变化让已有词获得新义。历史语义学归纳出词义变化的几种基本类型：

表 16: 词义变化的类型		
类型	机制	例子
词义扩大	指称范围变大	汉语”江””河”(专指长江黄河 → 泛指河流)；英语 holiday(圣日 → 假日)
词义缩小	指称范围变小	汉语”禽”(鸟兽总称 → 家禽)；英语 meat(食物 → 肉)、deer(动物 → 鹿)
词义转移	所指对象改变	汉语”走”(跑 → 走)、“涕”(眼泪 → 鼻涕)；英语 gay(快乐 → 同性恋)
词义贬化	感情色彩变坏	英语 villain(村民 → 坏人)、silly(幸福 → 愚蠢)
词义褒化	感情色彩变好	英语 knight(男孩 → 骑士)、nice(愚蠢 → 好)

科技词汇尤其依赖词义引申造出新义：web(蜘蛛网 → 万维网)、cloud(云 → 云计算)、window(窗 → 窗口)、desktop(桌面 → 桌面系统)、virus(病毒 → 计算机病毒)。

4.8.3 比喻造词: 隐喻与转喻

比喻造词通过隐喻 (metaphor) 与转喻 (metonymy) 把具体概念投射到抽象领域，是最富创造性的构词方式：

- **隐喻 (Metaphor):** 用具体事物理解抽象概念。计算机领域几乎全部使用隐喻造词：鼠标 (mouse)、病毒 (virus)、防火墙 (firewall)、垃圾邮件 (spam)、窗口 (window)、桌面 (desktop)、云计算 (cloud)、瓶颈 (bottleneck)。汉语”鼠标”正是”鼠 + 标”的隐喻造词。
- **转喻 (Metonymy):** 用相关事物代替目标事物。白宫 (代美国政府)、华盛顿 (代美国政府)、华尔街 (代金融界)、皇冠 (代王权)、“红领巾”(代少先队员)。
- **提喻 (Synecdoche):** 用部分代整体 (或反之)。”人手”(hand 代工人)、“饭碗”(代工作)。

认知语言学认为，人类抽象思维本身就建立在隐喻之上 (“时间是金钱”“争论是战争”)，语言中的比喻造词只是这一认知机制的表层体现。

4.9 借词: 外来词的吸收

语言接触导致的词汇借入 (borrowing) 是最重要的”外部”造词来源。外来词进入汉语时, 要接受汉语语音、语法和构词规则的改造, 形成多种吸收方式:

表 17: 外来词的吸收方式

方式	机制	例子
音译	借音不借形	沙发 (sofa)、咖啡 (coffee)
意译	译义造新词	电脑 (computer)、足球 (football)
仿译	逐语素对应翻译	热狗 (hot dog)、黑板 (blackboard)
音义兼译	音义兼顾	可口可乐 (Coca-Cola)、黑客 (hacker)
借形	借字形不借音	电话、经济 (自日语)
语义借用	旧词借新义项	病毒 (→ 计算机病毒)

4.9.1 音译 (Transliteration)

音译 (Transliteration) 按源语读音用汉字转写, 汉字只表音、不表义:

- **纯音译:** 沙发 (sofa)、咖啡 (coffee)、巧克力 (chocolate)、的士 (taxi)、比基尼 (bikini)
- **音译 + 类名:** 在音译后加汉语类名帮助理解, 如”卡车”(car+ 车)、“啤酒”(beer+ 酒)、“芭蕾舞”(ballet+ 舞)、“艾滋病”(AIDS+ 病)
- **半音半意:** 前音译后意译, 如”冰淇淋”(ice-cream)、“呼啦圈”(hula-hoop)、“因特网”(internet)

音译词可能因方言读音不同而有异体, 如 chocolate 普通话作”巧克力”、粤语作”朱古力”; 人名、地名则按国家规定的音译规则处理 (如 Clinton→ 克林顿)。

4.9.2 意译 (Semantic Translation)

意译用本族语材料把外来概念整体翻译成新词, 不保留源语读音:

- 电脑 (computer)、软件 (software)、硬件 (hardware)、数据库 (database)
- 互联网 (Internet)、搜索引擎 (search engine)、足球 (football)、口香糖 (chewing gum)

意译词在汉语外来词中占相当比重: 汉语双音节为主、表意文字的特点, 使音译词 (如”德律风”) 往往被意译词 (如”电话”) 淘汰。意译与仿译的区别在于: 意译只翻译整体概念, 仿译还要保留源语的构词结构 (见下)。

4.9.3 仿译 (Calque)

仿译 (Calque, 又称借译、仿造) 把源语词的每个语素逐一翻译, 保留源语的内部结构:

- 热狗 (hot dog)、黑板 (blackboard)、马力 (horsepower)、超人 (superman)
- 冷战 (cold war)、蓝图 (blueprint)、瓶颈 (bottleneck)、超级市场 (supermarket)
- 千年虫 (millennium bug)、防火墙 (firewall)

仿译与意译的界限并不总是清晰: ”足球”(football) 既可以说是意译 (整体翻译概念), 也符合仿译的定义 (逐语素对应 foot= 足、ball= 球)。一般以”是否逐语素保留源语结构”来区分——热狗是仿译 (因为 hot dog 作为食物名与字面义无关, 只能是逐成分仿造), 电脑则是意译 (computer 没有可拆解的语素对应)。

4.9.4 音义兼译 (Phono-Semantic Matching)

音义兼译所选汉字既接近源语读音, 又能在意义上产生联想, 是”形神兼备”的理想译法:

- 可口可乐 (Coca-Cola)、黑客 (hacker)、维他命 (vitamin)、香波 (shampoo)
- 幽默 (humour)、逻辑 (logic)、俱乐部 (club)、奔驰 (Benz)、宝马 (BMW)
- 托福 (TOEFL)、雅思 (IELTS)

”可口可乐”既是 Coca-Cola 的音译, 又暗示”可口、快乐”; ”奔驰”既近 Benz 读音又暗示汽车飞驰; ”宝马”既近 BMW 的读音又令人联想到名马。这类译名音义兼得, 是语言学界公认的最佳译法。

4.9.5 借形 (Borrowing of Written Form)

借形直接借用源语的书写形式, 读音按本族语, 是汉字文化圈特有的借词方式。最典型的是汉语借自日语的”和制汉语词”——日本在明治维新时期用汉字创造或重新组合的大量译词, 随后回流中国:

- 汉语借自日语的”和制汉语”: 电话、经济、社会、干部、哲学、法律、美术、物理、化学、文化、主义、政党、义务
- 英语借自汉语 (借音): tofu(豆腐)、kung fu(功夫)、dim sum(点心)、typhoon(台风)、tea(茶)

借形与借音不同：英语借 *tofu* 属于音译 (借读音)，汉语借“经济”只借字形、读音完全是汉语的。由于日语词义也用汉字承载，汉语借形词几乎“无缝”融入词汇系统，成为现代汉语的基本词汇。

4.9.6 语义借用 (Semantic Loan)

语义借用不借字形、不借读音，只把源语词的一个新义项加在本族已有的词上：

- 病毒：本义“生物病毒”，借英语 *virus* 的引申义后增加“计算机病毒”
- 明星：本义“明亮的星”，借英语 *star* 的引申义后增加“演艺明星”
- 天使：本义“神的使者”，借英语 *angel* 的引申义后增加“善良的人”
- 人口爆炸、信息爆炸：仿译 *population explosion* 的同时，“爆炸”获得“急剧增加”的新义

语义借用与仿译的区别：仿译产生新词 (热狗是新的组合)，语义借用不产生新词、只是旧词获得新义。判断一个“新义”是自身引申还是语义借用，要看语言接触的历史。

例子 4.1 (同一外来概念可有不同吸收方式).

Coca-Cola → 可口可乐 (音义兼译) *laser* → 莱塞 (音译)/激光 (意译) (45)

telephone → 德律风 (音译)/电话 (借形自日语) (46)

taxi → 的士 (音译)/出租车 (意译) (47)

同一外来词往往音译与意译并存，最后由语言社区的选择淘汰其一部。

4.10 汉语的造字法: 六书

汉语的构词基础是汉字的构造。东汉许慎在《说文解字》中提出“六书”理论，系统归纳了汉字的构造与使用方式。其中象形、指事、会意、形声是造字法，转注、假借是用字法：

表 18: 六书: 汉字的构造方式

名称	性质	说明	字例
象形	造字法	直接描画事物形状	日月山水
指事	造字法	抽象符号/在象形上加点标示	上下刃本
会意	造字法	两个以上部件组合出新义	武信休森
形声	造字法	形符表义 + 声符表音	江河清湖
转注	用字法	同义字互相注释	考老
假借	用字法	借同音字记录新义	令长其

- **象形 (Pictographic):** 描摹客观事物的形状。”日”像太阳、”月”像月牙、”水”像流水、”山”像山峰。象形是最古老的造字法，但数量很少。
- **指事 (Indicative):** 用抽象符号标示位置或状态。”上””下”用一长横加一短横标示方位，”刃”在”刀”的象形上加一点，指出刀刃所在。
- **会意 (Associative compound):** 用两个或以上部件会合出新义。”休”= 人 + 木 (人倚树休息)、”明”= 日 + 月 (明亮)、”森”= 三木 (树木众多)。
- **形声 (Phonetic compound):** 由表义的形符和表音的声符构成，是汉字中最能产的造字法，占现代汉字的 80% 以上。”江”从水工声、”河”从水可声、”清”从水青声。近代化学元素”氦””氧””氢”等都是新造的形声字。部分声符还兼表意义 (如”悌”的声符”弟”兼提示”弟弟敬爱兄长”义)，称”形声兼会意”。
- **转注 (Mutual explanatory):** 同义字互相注释。”考””老”同义，许慎以”考”训”老”、以”老”训”考”。学界对转注历来有”互训说””部首说””语音说”等不同解释，尚无定论，一般归为用字法。
- **假借 (Phonetic loan):** 借用已有的同音字记录新词义。”令”本义命令，借作县令之”令”；”长”本义长久，借作官长之”长”；”其”本义簸箕，借作代词”其”。假借也是用字法，不造新字。

4.11 构词方式的跨语言对比

不同语言在构词方式的侧重上有明显差异，这本身也是跨语言比较的重要维度：

表 19: 不同语言构词方式的侧重			
方式	汉语	英语	日语
复合	极能产 (火车)	极能产 (blackboard)	极能产 (山道)
派生	较少 (词缀有限)	极能产 (-ness, re-)	极能产 (动词变形丰富)
混成	较少	能产 (brunch)	罕见
截短/缩写	较少 (北外)	能产 (lab, FBI)	常见 (スマホ)
借词	音译 + 意译 + 借形	直接借用 (sofa)	外来语音译 + 借形汉字词
六书造字	独有	—	—

这一节说明：词的创造有规律可循。复合、派生等”组合型”方式在汉语、英语、日语中都极其能产；缩短型方式 (截短、缩写、混成) 在英语中尤为活跃；而借词方式则与书写系统和文化接触密切相关——汉语的六书造字法与丰富的音译/意译/借形方式，正是汉字文化圈与外部语言长期接触的产物。

4.12 形态音位学

语素组合时常常发生语音变化, 研究这种变化的学科叫形态音位学 (Morphophonology)。最经典的例子是英语复数后缀的三种读音。

4.12.1 英语复数规则

$$\text{复数后缀} = \begin{cases} /s/ & \text{清辅音后 (cats)} \\ /z/ & \text{浊辅音/元音后 (dogs, bees)} \\ /ɪz/ & \text{咝音后 (buses, churches)} \end{cases} \quad (48)$$

形式化表示 (这是音系规则格式的典型应用):

$$\text{Plural} \rightarrow \begin{cases} [s]/[-\text{voice}, -\text{sibilant}]_ \\ [z]/[+\text{voice}]_ \text{ 或 } [+\text{sonorant}]_ \\ [ɪz]/[+\text{sibilant}]_ \end{cases} \quad (49)$$

这个规则不是英语独有的“拼写习惯”, 而是语音学上的普遍倾向——清音与清音相邻、浊音与浊音相邻 (语音同化)。在土耳其语、德语、俄语的复数/格后缀中可以看到完全相同的机制。

4.12.2 语素变体 (Allomorph)

复数语素 $\{-s\}$ 在 cats、dogs、buses 中有三个变体 $/s/$ 、 $/z/$ 、 $/ɪz/$, 它们是同一个语素的语素变体。异干法 (go/went) 是语素变体的极端情况——词根形式完全互补。

4.13 形态分析的形式化

4.13.1 有限状态形态学

形态分析可以建模为有限状态转换器 (FST, Finite-State Transducer): 一个把词的表层拼写映射为“词干 + 语法标注”序列的有限自动机。

$$\text{FST: } T \subseteq \Sigma^* \times \Sigma^* \quad (50)$$

例子 4.2.

输入: *cats*

输出: *cat +N +Pl*

FST 把表层形式 *cats* 转写为词汇层分析 *cat + N + Pl*。形态学自动机是许多 NLP 系统 (拼写检查、词形还原、机器翻译形态分析) 的基础。

4.13.2 双层面模型

著名的双层面形态学 (Koskeniemi, 1983) 把形态变化表示为两个层面的对应:

$$\text{词表层形式} \xleftrightarrow{FST} \text{词法分析} \quad (51)$$

规则示例:

$$\begin{array}{l} \text{Lexical: } cat + N + Pl \\ \xrightarrow{\text{拼写规则}} \\ \text{Surface: } cats \end{array} \quad (52)$$

例子 4.3 ($y \rightarrow i$ 拼写规则).

$$carry + Pl \xrightarrow{y \rightarrow ies} carries \quad (53)$$

双层面模型中, 词汇层面是 $carry + Pl$, 表层是 $carries$, FST 同时处理“插入 e ”和“ y 变 i ”两个操作。

4.14 构词规则的形式化

4.14.1 语素顺序约束

英语词缀有严格的线性顺序, 这是形态学中的普遍约束:

$$\text{词根} \rightarrow \text{派生前缀} \rightarrow \text{词根} \rightarrow \text{派生后缀} \rightarrow \text{屈折后缀} \quad (54)$$

例子 4.4.

$$un-happi-ness-es \quad (55)$$

- $un-$: 派生前缀
- $happi$: 词根
- $-ness$: 派生后缀
- $-es$: 屈折后缀

这个顺序不是偶然的: 屈折后缀永远在最外层 (英语中动词屈折不能出现在派生词缀之内)。汉语中同样存在顺序约束: “桌子们”合法而“*桌子”的复数须加“们”且不能提前。

4.14.2 形态生成的图论表示

词的形态结构可以看作一棵树 (形态树): 词根是根节点, 词缀是叶子:

$$\text{un-happiness: } \underbrace{un}_{\text{前缀}} + \underbrace{happi}_{\text{词根}} + \underbrace{ness}_{\text{后缀}} \quad (56)$$

4.15 形态类型学的形式刻画

上一章的孤立语/黏着语/屈折语/多式综合语四分法，可以在形态学的框架下精确刻画。定义语素密度 (词素比率) 为：

$$\text{形态综合度} = \frac{\# \text{语素}}{\# \text{词}} \quad (\text{对一段语料取平均}) \quad (57)$$

- 孤立语 (汉语): 比率 ≈ 1
- 黏着语 (土耳其语): 比率高且词缀边界清晰 (一一对应)
- 屈折语 (俄语): 比率较高且词缀融合 (一个词缀多重意义)
- 多式综合语 (因纽特语): 比率极高 (一个词内整合主语宾语)

这个量化指标是跨语言比较的直接工具：给定两段平行文本，计算各自的语素密度，就能客观比较两种语言在形态上的“综合性”差异。

4.16 本章小结

形态学研究词内的结构世界：语素是最小的意义单位，屈折与派生是两大构词机制，语素变体和语音规则把深层形式映射到表层拼写。形态学既能用有限状态转换器精确计算，又是语言类型学 (孤立/黏着/屈折/复综) 的核心坐标。不同语言在形态上的巨大差异——从汉语的几乎没有屈折，到俄语的复杂格系统，到日语的黏着堆叠——正是理解“语言之间差异”的最佳入口，我们将在最后一章系统比较。下一章上升到句子的组织方式：句法。

5 句法

5.1 句法概述

句法 (Syntax) 研究词如何组合成短语和句子的规则。句法不仅告诉我们什么合法 (合法句子), 也告诉我们为什么合法——合法性与句子结构的层次性、递归性紧密相关。

例子 5.1 (句法的层级性).

The cat 在句中作为整体出现 $\rightarrow$ *The cat sat on the mat* (58)

"the cat" 这个名词短语 (NP) 可以出现在 "_____ sleeps" "I saw _____" "_____ is big" 等位置, 说明句法是成分组成的层级结构, 而不是词的线性序列。

句法的核心问题:

- 短语结构如何组织 (成分分析)
- 词类 (范畴) 如何决定组合方式
- 语序为何因语言而异 (跨语言比较的关键)
- 有限的规则如何生成无限的句子 (递归性)

5.2 短语结构语法

5.2.1 基本短语规则


短语结构语法用上下文无关文法式的重写规则描述句子结构:

$$\begin{aligned}
 S &\rightarrow NP VP \\
 NP &\rightarrow Det (Adj) N (PP) \\
 VP &\rightarrow V (NP) (PP) (Adv) \\
 PP &\rightarrow P NP \\
 AdjP &\rightarrow (Adv) Adj \\
 AdvP &\rightarrow (Adv) Adv
 \end{aligned}
 \tag{59}$$

这里 S (句子)、 NP (名词短语)、 VP (动词短语)、 PP (介词短语) 是非终结符, 规则递归地组合出无限多的句子。注意 $VP \rightarrow V (NP)$ 允许多种结构的递归嵌套——这正是有限规则生成无限句子的机制。

5.2.2 句法树示例

”The cat sat on the mat”:



句法树的每个子树对应一个成分 (constituent)，成分性是短语结构语法的基本概念：一个句子可以”被测试”出成分 (前置、替代、省略测试)。

5.2.3 短语结构语法的类型学参数

同一套重写规则在不同语言中只是语序不同。比较英语与日语：

英语: $S \rightarrow NP VP$ (中心词在前: 动-宾) (60)

日语: $S \rightarrow NP VP$ (中心词在后: 宾-动) (61)


日语: $NP \rightarrow NP P$ (后置词) (62)

短语结构”骨架”惊人地一致，差异集中在中心词的方向——这一观察直接导向 X-bar 理论中的头参数。

5.3 X-bar 理论

X-bar 理论 (Chomsky, 1970) 提供统一的短语结构模板，消除了为每种短语分别写规则的必要。每个短语 XP 都有一个中心词 X，模板如下：

$$\begin{aligned}
 XP &\rightarrow (Spec) X' \\
 X' &\rightarrow X (Complement) \\
 X' &\rightarrow (Adjunct) X'
 \end{aligned}
 \tag{63}$$



X-bar 统一刻画了名词短语 NP、动词短语 VP、介词短语 PP、形容词短语 AP 等一切短语：如 NP 的中心词是 N，VP 的中心词是 V。通过递归的 X' 层，X-bar 允许任意多个修饰语 (Adjunct) 附着，同时保持每个短语只有一个中心词和一个补足语。

5.3.1 头参数与跨语言差异

例子 5.2 (头参数).

英语 (中心词在前): $NP = P + NP$ (前置词: *in the house*) (64)

日语 (中心词在后): $NP = NP + P$ (后置词: 家の中) (65)

英语 (动-宾): $VP = V + NP$ (*eat an apple*) (66)

日语 (宾-动): $VP = NP + V$ (りんごを食べる) (67)

头参数 (*Head parameter*) 决定了中心词在其补足语之前还是之后。这一参数贯穿整个短语结构，解释了英语 (中心词前) 与日语 (中心词后) 在语序上的系统性差异。我们将在最后一章详细展开。

5.4 依存语法

依存语法 (Dependency Grammar) 不关心成分层级，而是关注词与词之间不对称的二元关系。每个词有一个中心词 (head)，全句的中心词是动词：

$$\text{依存树} = (W, E) \quad (68)$$

其中 W 是词集合， $E \subseteq W \times R \times W$ 是有标记的依存边。

5.4.1 依存关系类型

表 20: 常见依存关系 (以英语为例)

关系	示例
nsubj (名词主语)	cat sleeps
dobj (直接宾语)	eat apple
amod (形容词修饰)	red car
det (限定词)	the cat
prep (介词修饰)	sit on mat
pobj (介词宾语)	on mat
advmod (副词修饰)	very good
aux (助动词)	has eaten

5.4.2 依存语法的跨语言优势

依存语法对语序高度“宽容”：不论动词在宾语前 (SVO) 还是后 (SOV)，动词-宾语的依存关系都成立。这使依存表示成为跨语言句法分析 (Universal Dependencies 项目) 的标准格式——同一棵“语义骨架”在不同语言中有不同的表层语序，依存树完美地分离了“关系”与“语序”。这与短语结构语法形成互补：短语结构刻画成分层级，依存结构刻画中心词-从属关系。

5.5 转换生成语法

5.5.1 深层结构与表层结构

早期生成语法 (1957-1980 年代) 区分深层结构与表层结构：

$$\text{深层结构 (DS)} \xrightarrow{\text{转换规则}} \text{表层结构 (SS)} \quad (69)$$

深层结构承载论元结构与语义解释，表层结构是实际说出的形式。转换规则 (移动、插入、删除) 把深层结构映射到表层。这一机制使生成语法可以优雅地处理“同一个意思的多种句子形式”(主动/被动、陈述/疑问) 之间的关系。

5.5.2 Wh-移动

$$\text{DS: You saw } \underline{\text{what}} \quad (70)$$

$$\text{SS: What}_i \text{ did you see } t_i \quad (71)$$

Move- α : 将成分 α 移至指定位置, 留下语迹 t (72)

疑问词 *what* 从宾语位置移动到句首, 原位置留下语迹 t_i (下标的 i 表示同标索引, 标明移动轨迹)。语迹理论解释了疑问句为何不能从某些位置提取 (如孤岛约束)。

5.5.3 孤岛约束

某些结构是”移动禁区”: 成分不能从中提取。

*What did you ask whether John bought _ ? (whether 从句是孤岛) (73)

这类约束在不同语言中表现出惊人的一致性, 说明它们源于语法的普遍原则 (Subadjacency/条件约束), 而非个别语言的规则——这是普遍语法的重要证据。

5.6 最简方案

5.6.1 合并 (Merge)

最简方案 (Chomsky, 1995-) 把语法简化到极致: 句法操作只剩下合并 (Merge)。Merge 把两个句法对象组合成一个新对象:

$$\text{Merge}(\alpha, \beta) = \{\alpha, \{\alpha, \beta\}\} \quad (74)$$

合并是递归的, 因而能生成无限结构:

$$\begin{aligned} \text{Merge}(\text{the}, \text{cat}) &= \{\text{the}, \{\text{the}, \text{cat}\}\} = NP \\ \text{Merge}(NP, \text{saw}) &= \{NP, \{NP, \text{saw}\}\} = VP \\ \text{Merge}(VP, NP) &= \{VP, \{VP, NP\}\} = S \end{aligned} \quad (75)$$

5.6.2 移动是合并的副产品

最简方案中, 移动 (如 Wh-移动) 只是”内部合并”(再合并已经合并过的成分)。语言的递归性和”离散无限性”(离散的、无限的能力) 由此获得最简约的解释:

$$\text{语言的生成能力} = \text{合并的递归应用} \quad (76)$$

5.7 范畴语法

5.7.1 组合范畴语法 (CCG)

范畴语法把每个词与一个范畴关联，组合规则是纯粹的“函数应用”。范畴用斜线标注参数方向：

$$\begin{aligned} \text{cat} &:= N \\ \text{the} &:= NP/N \\ \text{sleeps} &:= S \backslash NP \\ \text{loves} &:= (S \backslash NP)/NP \end{aligned} \tag{77}$$

5.7.2 组合规则

$$\begin{aligned} X/Y \quad Y &\Rightarrow X \quad (\text{前向应用}) \\ Y \quad X \backslash Y &\Rightarrow X \quad (\text{后向应用}) \end{aligned} \tag{78}$$

例子 5.3 (CCG 推导).

$$\frac{\text{the} : NP/N \quad \text{cat} : N}{NP} \quad (\text{前向应用}) \tag{79}$$

“the cat”的范畴 NP/N 与 N 结合，前向应用得到 NP 。CCG 的范畴系统与语义学中的类型论 (最后一章的 *Lambda* 演算) 完全同构：每个范畴对应一个语义类型，句法推导直接对应语义组合。

CCG 的一个重要优点是它的组合规则能产生松散成分 (non-constituent) 协调，使它在机器翻译和跨语言句法分析中特别有用。

5.8 树邻接文法 (TAG)

TAG 使用两棵树作为基本对象：

$$G_{TAG} = (\Sigma, V, I, A, S) \tag{80}$$

其中 I 是初始树集合， A 是辅助树集合。

操作：

- **替换 (Substitution)**: 将一棵树插入叶节点
- **附加 (Adjoining)**: 将辅助树插入内部节点 (可以描述长距离依赖和修饰语的递归嵌套)

TAG 的表达能恰好处于上下文无关文法与上下文有关文法之间 (温和上下文有关)，能处理自然语言中的跨串依赖，同时保持多项式可解析性。这是 TAG 在计算语言学中占据重要地位的原因。

5.9 概率句法分析

5.9.1 概率上下文无关文法 (PCFG)

把概率赋给每条产生式，就得到 PCFG。它允许在歧义句法树之间选择概率最高的一棵：

$$P(T|S) = \prod_{r \in T} P(r) \quad (81)$$

其中 T 是句法树， S 是句子， r 是产生式规则。PCFG 可以从语料自动学习 (最大似然估计)，是统计句法分析的基础。

5.9.2 CKY 算法

CKY 算法是 PCFG 句法分析的标准动态规划算法 (要求文法为 CNF)：

$$\pi[i, j, X] = \max_{Y, Z, k} P(X \rightarrow YZ) \cdot \pi[i, k, Y] \cdot \pi[k + 1, j, Z] \quad (82)$$

$$\pi[i, i, X] = P(X \rightarrow w_i) \quad (83)$$

CKY 自底向上填表：先算单个词的可能范畴，再逐步合并相邻区间，最终检查 $\pi[1, n, S]$ 是否为最大概率。对长度为 n 的句子，复杂度为 $O(n^3)$ 。CKY 在词性标注、机器翻译、语音识别的句法约束中被广泛使用。

5.10 跨语言的句法参数

句法理论积累的洞见可以概括为一组跨语言比较的参数 (详见最后一章)：

- **头参数**：中心词在前 (英语) vs. 中心词在后 (日语、土耳其语)
- **主语优先 vs. 话题优先**：英语、日语是主语优先，汉语、朝鲜语是话题优先
- **Pro-省略 (Pro-drop)**：意大利语、西班牙语、日语可省略主语，英语、法语、德语不可
- **疑问词移动 vs. 原位**：英语疑问词移动，汉语、日语疑问词留在原位
- **格标记 vs. 语序**：俄语靠格标记，汉语靠语序

例子 5.4 (疑问词原位 vs 移动)。

英语: *What did you see _ ?* (移动) (84)

汉语: 你看到了什么? (原位) (85)

日语: あなたは何を見たか? (原位) (86)

同一命题”你看见了什么”在三语言中的句法实现截然不同：英语把疑问词提到句首，汉语和日语留在宾语位置。这是”参数差异”最直观的例子之一。

5.11 本章小结

句法是语言学的核心：短语结构语法刻画成分层级，X-bar 理论统一短语模板并引出头参数，依存语法刻画中心词关系且天然跨语言友好，转换语法与最简方案追问”句法操作的普遍形式”，范畴语法与 TAG 提供计算上可实现的句法形式体系，PCFG 与 CKY 让句法分析可以自动化。句法的深层启示是：人类语言共享一套普遍原则（递归合并、中心词-补足语结构），而语言之间的差异源于少数参数的取值。这正是最后一章”不同语言之间的差异”的理论基础。下一章转向意义：语义学。

6 语义学

6.1 语义学概述

语义学 (Semantics) 研究语言单位——词、短语、句子——的意义。形式语义学的基本信念是：意义可以用数学对象刻画，句子的意义可以用真值条件 (在什么条件下为真) 来把握。

知道一个句子的意义 = 知道它在什么条件下为真 (87)

语义学与语用学 (Pragmatics) 的分界：语义学研究“句子说了什么”(不依赖语境的字面意义)，语用学研究“说话人想表达什么”(依赖语境的含义)。例如“你能把盐递过来吗”字面意义是疑问，语用意义是请求。

6.2 词义关系

6.2.1 基本关系

- 同义 (Synonymy): 意义相同或几乎相同, $\text{big} \approx \text{large}$
- 反义 (Antonymy): 意义相反。分互补反义 (hot/cold 非此即彼式不严格) 与程度反义, 还有方向反义 (buy/sell)
- 上下义 (Hyponymy): 从属关系, $\text{dog} \subset \text{animal}$, dog 是 animal 的下义词
- 整体部分 (Meronymy): 部分-整体关系, $\text{wheel} \subset \text{car}$
- 多义 (Polysemy): 一词多义且意义相关, bank (银行/河岸)
- 同音 (Homophony): 发音相同意义无关, flower/flour

这些关系可以形式化为集合之间的包含、相交、矛盾关系：

$[\text{dog}] \subseteq [\text{animal}]$ (上下义 = 集合包含) (88)

6.3 形式语义学

6.3.1 模型论语义

定义 6.1 (模型). 模型 $M = \langle D, I \rangle$

- D : 论域 (*Domain of discourse*)——语境中的实体集合

- I : 解释函数 (*Interpretation function*)——把专名映射到实体、把谓词映射到性质 (集合)

例子 6.1. 模型 M : $D = \{\text{猫 } 1, \text{猫 } 2, \text{狗 } 1\}$, $I(\text{cat}) = \{\text{猫 } 1, \text{猫 } 2\}$, $I(\text{Fluffy}) = \text{猫 } 1$ 。
于是 "*Fluffy is a cat*" 在 M 中为真, 因为 $I(\text{Fluffy}) \in I(\text{cat})$ 。

6.3.2 真值条件语义

句子意义的真值条件定义:

$$\llbracket \phi \rrbracket^M = \begin{cases} 1 & \text{若 } \phi \text{ 在模型 } M \text{ 中为真} \\ 0 & \text{若 } \phi \text{ 在模型 } M \text{ 中为假} \end{cases} \quad (89)$$

例子 6.2.

$$\begin{aligned} \llbracket \text{Snow is white} \rrbracket &= 1 \quad \text{当且仅当雪是白的} \\ \llbracket \text{Cats are dogs} \rrbracket &= 0 \end{aligned}$$

6.3.3 谓词逻辑翻译

句子翻译为一阶逻辑公式, 谓词的语义即论域的子集:

$$\llbracket \text{cat}(x) \rrbracket^M = 1 \iff I(x) \in I(\text{cat}) \subseteq D \quad (90)$$

例子 6.3.

$$\text{"Every dog barks"} \implies \forall x [\text{dog}(x) \rightarrow \text{bark}(x)] \quad (91)$$

6.4 Lambda 演算与组合语义

6.4.1 Lambda 演算基础

$$\begin{aligned} \text{项: } M, N &::= x \mid \lambda x. M \mid (M \ N) \\ \beta\text{-归约: } (\lambda x. M)(N) &\rightarrow M[x := N] \end{aligned} \quad (92)$$

β -归约是计算规则: 把函数应用到参数, 用参数替换函数体内的绑定变量。这为语义组合提供了机械的计算手段。

6.4.2 词项语义

$$\begin{aligned}
 \llbracket \text{cat} \rrbracket &= \lambda x. \text{cat}(x) \\
 \llbracket \text{sleep} \rrbracket &= \lambda x. \text{sleep}(x) \\
 \llbracket \text{love} \rrbracket &= \lambda y. \lambda x. \text{love}(x, y)
 \end{aligned}
 \tag{93}$$

注意及物动词 love 是“先取宾语再取主语”的柯里化函数。语义类型与句法范畴严格对应： N 对应个体 (e)， S 对应真值 (t)， NP/N 对应函数类型等——这就是类型-句法同构 (对应 CCG 的范畴系统)。

6.4.3 组合示例

“The cat sleeps”:

$$\begin{aligned}
 \llbracket \text{the} \rrbracket &= \lambda P. \iota x. P(x) \quad (\iota \text{ 是唯一性算子}) \\
 \llbracket \text{cat} \rrbracket &= \lambda x. \text{cat}(x) \\
 \llbracket \text{the cat} \rrbracket &= \iota x. \text{cat}(x) \\
 \llbracket \text{sleeps} \rrbracket &= \lambda x. \text{sleep}(x) \\
 \llbracket \text{The cat sleeps} \rrbracket &= \text{sleep}(\iota x. \text{cat}(x))
 \end{aligned}
 \tag{94}$$

整个推导完全由句法结构 (树) 驱动：每个成分的意义是子成分意义按组合规则的机械应用。这是弗雷格组合原则 (Compositionality) 的形式实现：整体意义是部分意义 + 组合方式的函数。

6.5 量词语义

6.5.1 广义量词

普通名词短语如“every dog”不能简单地翻译为个体，需要广义量词理论。量词是“名词谓词与动词短语谓词之间关系的函数”：

$$\begin{aligned}
 \llbracket \text{every} \rrbracket &= \lambda P. \lambda Q. \forall x [P(x) \rightarrow Q(x)] \\
 \llbracket \text{some} \rrbracket &= \lambda P. \lambda Q. \exists x [P(x) \wedge Q(x)] \\
 \llbracket \text{no} \rrbracket &= \lambda P. \lambda Q. \neg \exists x [P(x) \wedge Q(x)] \\
 \llbracket \text{most} \rrbracket &= \lambda P. \lambda Q. |P \cap Q| > |P \setminus Q|
 \end{aligned}
 \tag{95}$$

广义量词是“集合之间的关系”，因此可以统一地表示“most dogs”这种一阶逻辑难以直接表达的量词。

6.5.2 量词作用域

量词之间的相对顺序产生不同的解读，导致歧义：

Every student read a book

解读 1 (每一 > 存在): $\forall x[\text{student}(x) \rightarrow \exists y[\text{book}(y) \wedge \text{read}(x, y)]]$ (96)

解读 2 (存在 > 每一): $\exists y[\text{book}(y) \wedge \forall x[\text{student}(x) \rightarrow \text{read}(x, y)]]$

解读 1: “每个学生读了一本书 (可能是不同的书)”；解读 2: “有一本书，每个学生都读了它 (同一本书)”。形式语义学用作用域 (scope) 解释这种歧义，量词作用域越广 (越靠左的算子)，辖域越大。

6.6 内涵语义

6.6.1 可能世界语义

外延语义无法处理“相信”“可能”等内涵语境。可能世界语义学 (Kripke, 1963) 引入可能世界的概念：

$$\llbracket \phi \rrbracket^{M,w,g} \in \{0,1\} \quad (97)$$

其中 w 是可能世界， g 是赋值函数。

6.6.2 模态算子

$$\begin{aligned} \llbracket \Box \phi \rrbracket^{M,w} = 1 & \text{ 当且仅当 } \forall w' \in R(w) : \llbracket \phi \rrbracket^{M,w'} = 1 \\ \llbracket \Diamond \phi \rrbracket^{M,w} = 1 & \text{ 当且仅当 } \exists w' \in R(w) : \llbracket \phi \rrbracket^{M,w'} = 1 \end{aligned} \quad (98)$$

$\Box$ (必然) 要求 ϕ 在所有可达世界中为真， $\Diamond$ (可能) 要求 ϕ 在某个可达世界中为真。可达关系 R 可以取不同的性质 (自反、传递等)，对应不同的模态逻辑系统 (T、S4、S5 等)。

6.6.3 命题态度

$$\text{“John believes that } p\text{”} = \text{John 与命题 } \lambda w. \llbracket p \rrbracket^w \text{ 处于“相信”关系} \quad (99)$$

内涵语境 (相信、希望、知道) 中的从句指涉的不是真值而是命题 (从世界到真值的函数)。这解释了为什么 “John believes that the morning star is the evening star” 中两个名称不能随便互换——它们的外延相同 (金星) 但内涵 (命题角色) 不同。

6.7 时间与体态语义

6.7.1 时态与时间论域

时态把时间引入语义。用时间参数化的模型：

$$[[\text{walked}]]^{M,g,t} = 1 \iff \text{主体在 } t' \text{ 行走, 且 } t' < t \quad (100)$$

6.7.2 体态 (Aspect)

体态刻画动作的内部时间结构：

- **完成体 (Perfective)**: 把事件看作完整整体, ”他读了那本书”
- **进行体 (Imperfective)**: 从内部看事件进行中, ”他正在读那本书”

汉语通过助词”了/着/过”表达体貌, 英语用形态 (-ed/-ing) 表达时体, 斯拉夫语 (俄语) 把完成/未完成固化为动词的语法对 (perfective/imperfective)。这是跨语言差异在语义层面的体现。

6.8 词汇语义表示

6.8.1 框架语义

Fillmore 的框架语义学用”语义框架”描述词义：一个词激活一个包含参与者角色 (槽位) 的场景。

$$\text{Buy: } \langle \text{Buyer, Seller, Goods, Money} \rangle \quad (101)$$

例子 6.4.

$$\text{John bought the car from Mary for \$500} \quad (102)$$

$$\text{Buyer=John, Goods=the car, Seller=Mary, Money=\$500} \quad (103)$$

同一场景可以用不同动词的视角表述: buy (买者视角)、sell (卖者视角)、pay (价钱视角)。框架语义把词汇语义与句法论元结构连接起来, 是 *FrameNet* 等资源的理论基础。

6.8.2 论元结构 (Theta 角色)

动词的语义论元映射到句法位置：

$$\text{give: } \langle \text{施事 (Agent), 受事 (Theme), 接受者 (Recipient)} \rangle \quad (104)$$

$$\text{John} \xrightarrow{\text{Agent}} \text{gave} \quad \text{a book} \xrightarrow{\text{Theme}} \text{to Mary} \xrightarrow{\text{Recipient}} \quad (105)$$

论元结构在不同语言中体现为格系统或语序：俄语用与格 (dative) 标记接受者, 汉语用”给”介宾结构, 日语用助词”に”标记。动词的论元结构是”语义与句法的接口”。

6.8.3 语用与语义的边界: 预设与含义

- 蕴含 (Entailment): 逻辑必然, A 蕴含 B 指只要 A 真 B 必真
- 预设 (Presupposition): 隐含前提, ”他的哥哥来了” 预设”他有哥哥”
- 会话含义 (Implicature): 格里斯的语用推理, ”有些学生来了” 常暗示”不是全部”

6.9 跨语言的语义共性

形式语义学揭示了一个重要事实: 语义结构高度跨语言一致。无论英语、汉语还是日语, 都区分施事与受事、都有量词、都区分必然与可能。语言之间的差异主要不在”意义本身”, 而在”意义的表层编码方式”:

- 英语用量词化的名词短语 + 语序表达”谁对谁做了什么”
- 汉语用语序 + 话题结构表达信息结构
- 日语用助词 + 形态表达论元角色
- 俄语用格标记表达论元角色

这个洞见是最后一章的核心主题之一: 普遍语义 + 参数化编码 = 语言差异。

6.10 本章小结

语义学研究意义, 形式语义学用模型、真值条件、Lambda 演算、可能世界和广义量词把意义精确化。组合原则告诉我们意义如何由部分组合, 内涵语义处理相信与模态, 框架语义连接词汇与论元结构。最重要的收获是: 不同语言在语义层面高度共享 (论元角色、量词、时态语义是普遍的), 差异集中在编码策略。接下来我们进入语音层面, 看看语言在”声音”上如何不同。

7 音系学与语音学

7.1 语音学 vs 音系学

- **语音学 (Phonetics):** 研究语音的物理与生理属性 (发音、声学、感知), 处理的是连续的声音
- **音系学 (Phonology):** 研究语音在特定语言系统中的功能和模式, 处理的是离散的单位 (音位)

语音学回答”声音是什么”(物理现实), 音系学回答”声音在一个语言中起什么作用”(系统功能)。同一物理声音在不同语言中可能有不同地位: 送气塞音 [pʰ] 在英语中是 /p/ 的音位变体 (不区分意义), 在印地语中却与 /p/ 对立 (区分意义)。这是跨语言差异的起点——每种语言从语音的连续空间中选取自己的离散系统。

7.2 国际音标 (IPA)

IPA 提供语音的标准化符号系统, 一个符号对应一个音位/音素, 避免”拼写与发音不一致”的问题 (英语拼写 world 中有 o 但发音没有)。

表 21: 辅音示例

IPA	描述	例词	特征
/p/	清双唇塞音	pat	[-voice, +bilabial, +stop]
/b/	浊双唇塞音	bat	[+voice, +bilabial, +stop]
/t/	清齿龈塞音	top	[-voice, +alveolar, +stop]
/k/	清软腭塞音	cat	[-voice, +velar, +stop]
/s/	清齿龈擦音	sit	[-voice, +alveolar, +fricative]
/m/	双唇鼻音	mat	[+voice, +bilabial, +nasal]

7.2.1 元音系统

元音按舌位 (高/低、前/后) 和圆唇度定位。英语有 12-15 个元音, 日语只有 5 个 (/a i u e o/), 这是跨语言音位库存差异的典型。汉语普通话约有 6 个元音音位 (连同声调形成声调音位)。

7.3 区别特征

音位可用二元特征矩阵表示, 这就是区别特征理论 (雅柯布森/乔姆斯基-哈雷 SPE)。特征把语音描述为”开关”的组合:

$$/p/ = \begin{bmatrix} +\text{consonantal} \\ -\text{sonorant} \\ -\text{voice} \\ +\text{bilabial} \\ -\text{continuant} \end{bmatrix} \quad (106)$$

区别特征的价值:

- 用最少的特征区分一种语言的全部音位 (分类的简约性)
- 自然类 (Natural class): 共享特征集的音位在规则中表现一致
- 解释规则: 音系规则写在一组特征上而非单个音位上

例子 7.1. 英语复数规则的三种变体 ($/s/$ $/z/$ $/ɪz/$) 正是由 $[-\text{voice}]$ 、 $[+\text{sibilant}]$ 等特征类决定的 (见形态学一章)。规则”清辅音后读清音”实际上是特征 $[\text{voice}]$ 的语音同化。

7.4 音系规则

7.4.1 SPE 规则格式

音系规则的标准格式 (源自《音系学模式》SPE):

$$A \rightarrow B / C _ D \quad (107)$$

读作: A 在 C 和 D 之间变为 B。其中 C_D 是触发环境。

7.4.2 英语复数规则

规则 1: $\emptyset \rightarrow [\text{ɪz}] / [+ \text{sibilant}] _$

规则 2: $[z] \rightarrow [s] / [-\text{voice}] _$ (108)

规则 3: $\emptyset \rightarrow [z] / \text{elsewhere}$

应用顺序 (规则有序性):

$$\begin{aligned} /bʌs/ + \text{Pl} &\xrightarrow{R1} bʌsɪz \quad (\text{buses}) \\ /kæt/ + \text{Pl} &\xrightarrow{R3} kæts \quad (\text{cats}) \\ /dɒg/ + \text{Pl} &\xrightarrow{R3} dɒgz \quad (\text{dogs}) \end{aligned} \quad (109)$$

注意复数语素的深层形式统一取 /z/ (浊音)，规则 2 在清辅音后把 /z/ 清化为 /s/。这种“底层形式 + 规则推导”的思路是生成音系学的核心：底层形式存储于词库，表层形式是规则应用的输出。

7.5 音位与音位变体

定义 7.1 (音位). 音位 (*Phoneme*) 是能区分意义的最小语音单位。两个音若出现在相同的环境中且能区分意义，就是不同的音位 (最小对立体测试)。

$$/p/ \text{ vs } /b/ \Rightarrow \text{pat vs bat} \quad (\text{最小对立体}) \quad (110)$$

定义 7.2 (音位变体). 音位变体 (*Allophone*) 是音位的条件变体，不区分意义，其分布由语音环境决定。

$$/p/ \rightarrow \begin{cases} [p^h] & \text{词首 (pin)} \\ [p] & \text{/s/后 (spin)} \end{cases} \quad (111)$$

英语中 $[p^h]$ 和 $[p]$ 属于同一个音位 $/p/$ (互补分布)，说英语的人甚至察觉不到区别。而泰语、印地语中 $[p^h]$ 和 $[p]$ 是不同音位。音位对立/变体分布正是跨语言音系差异的集中体现：


- 英语：送气与不送气不对立 (同一音位)
- 印地语、泰语、汉语吴语：送气与不送气对立 (不同音位)

7.6 音节结构

音节组织规则因语言而异。音节结构：

$$\text{音节} = \text{Onset} + \text{Rhyme} \quad (112)$$

$$\text{Rhyme} = \text{Nucleus} + \text{Coda} \quad (113)$$



7.6.1 音节模板的跨语言差异

- 汉语普通话：音节结构非常受限，最大为 (C)V(N) 或 (C)V(ŋ)，没有辅音丛
- 日语：最大为 (C)(y)V(N/Q)，N 是拨音、Q 是促音，禁止辅音丛
- 英语：允许复杂辅音丛，如 *strengths* /streŋθs/ 有连续辅音
- 波兰语：允许极复杂的辅音丛，如 *bezwzględny*(无情的)

这些差异决定了”听感”和”拼读”上的巨大区别：日本人学英语会在辅音丛中插入元音 (eskuriputo)，中国人把英语音节套进普通话模板。音系学的目标之一就是精确刻画每种语言的音节模板。

7.7 声调与重音

7.7.1 声调语言

声调 (音高模式) 在声调语言中区分词义。汉语普通话四声：

妈 mā [55]	高平	(114)
麻 má [35]	高升	
马 mǎ [214]	降升	
骂 mà [51]	全降	

声调语言在世界上相当常见：汉藏语系、东南亚语言 (泰语 5 个声调、越南语 6 个声调)、撒哈拉以南非洲的很多语言 (约鲁巴语用声调区分词义)，都是声调语言。普通话四声可以用五度制 ([55]、[35]、[214]、[51]) 精确表示——这是调值的离散编码。

7.7.2 重音语言

重音 (响度/音高/时长的强调) 在重音语言中起组织作用。重音可以是：

- **固定重音**：重音位置由规则固定 (如波兰语几乎总是倒数第二音节)
- **自由重音**：重音位置区分词义 (如俄语 мýка 面粉 vs мыká 痛苦)
- **音高重音**：每个词只有一个高音调 (日语、瑞典语)

英语名词重音规则 (简化)：

重音落在倒数第三个音节，若倒数第二音节为重音节 (115)

7.7.3 日语是声调还是重音语言？

日语属于音高重音 (pitch accent) 语言：每个词最多一个高调峰，单词之间通过调峰位置区分：はし (chopsticks, 头高型) vs はし (bridge, 尾高型)。这是介于声调语言与重音语言之间的类型，也是跨语言音系差异的极好案例。

7.8 韵律与语调

- **音节/节拍等时性**: 英语是重音计时 (stress-timed), 汉语、日语是音节/莫拉计时 (syllable-timed / mora-timed)
- **语调 (Intonation)**: 句子的整体音高曲线表达语气 (陈述降调、疑问升调)。语调在所有语言中都存在，但功能有别：汉语中语调与字调叠加

普通话: 字调 (词内) + 语调 (句内) 叠加, 语调只改变音高基线 (116)

7.9 优选论 (Optimality Theory)

7.9.1 OT 框架

优选论 (Prince & Smolensky, 1993) 用约束排序 + 并行评估取代串行规则:

定义 7.3 (OT 框架). *OT* 由以下三部分组成:

- *GEN*: 生成候选输出集合 (所有可能的表层形式)
- *CON*: 普遍约束集合 (标记性约束、忠实性约束)
- *EVAL*: 根据约束排序评估候选, 选出违反最少 (违反最高层级约束最少) 的候选

$$\text{最优输出} = \arg \min_{c \in \text{GEN}} \sum_i w_i \cdot \text{Violations}(c, C_i) \quad (117)$$

7.9.2 约束的类型

- **标记性约束 (Markedness)**: 禁制复杂/难发音的结构 (如 NO-CODA 禁止音节尾辅音、ONSET 要求音节有起音)
- **忠实性约束 (Faithfulness)**: 要求输出与输入一致 (如 MAX 禁止删音、DEP 禁止插音)

语言差异在 OT 中表现为约束排序的不同: 每种语言是普遍约束集合的一种排序。

例子 7.2. 英语允许音节尾辅音 (cat), 因为忠实性约束 MAX 排序高于标记性约束 NO-CODA; 而部分语言 (如某些波利尼西亚语) 禁止音节尾辅音, 是因为 NO-CODA 排序更高。同一个普遍约束集合, 不同的排序 = 不同的语言音系。这为”跨语言差异的形式化”提供了最优雅范例: 差异 = 参数 (排序) 选择。

7.9.3 OT 与跨语言差异

OT 的意义在于把语言差异归约为排序: 假定所有语言共享同一个约束集合 (普遍语法), 不同语言只是对约束的相对优先级排列不同。这与原则与参数理论 (语法参数的二进制取值) 异曲同工, 共同体现了”普遍原则 + 参数化差异”的跨语言比较纲领。

7.10 语音变化与历时音系学

7.10.1 常见的音变

- 同化 (Assimilation): 音素变得与邻近音相似 (英语复数清浊同化)
- 元音大转移: 英语 15-17 世纪的元音系统性移位 (现代英语拼写与发音不一致的原因)
- 音位化/去音位化: 音位变体分裂为新音位, 或音位对合并

7.10.2 汉语语音史

中古汉语到现代普通话发生了系统的辅音、元音、声调演变, 音韵学用等韵图精确记录了这种演变。汉语的声调正是从早期无声调、经过声母清浊消失而”补偿”产生的。

7.11 本章小结

语音学测量声音, 音系学组织声音。区别特征、音系规则、音位与音位变体、音节模板、声调与重音、优选论共同构成了研究”语音如何系统化”的完整工具箱。跨语言在音系上的差异极为显著且容易感知: 音位库存、送气对立、音节结构、声调有无, 都让不同语言”听起来”截然不同。而优选论等理论告诉我们: 这些差异仍然来自共享原则的参数化排列。下一章进入计算语言学, 看看语言知识如何变成可计算的系统。

8 计算语言学

8.1 概述

计算语言学 (Computational Linguistics, CL) 使用计算方法研究语言，是自然语言处理 (NLP) 的理论基础。它既是语言学的分支 (用计算模型验证语言理论)，也是计算机科学的分支 (让计算机理解和生成语言)。

$$\text{CL} = \text{语言学理论} \times \text{算法与统计模型} \quad (118)$$

本书前几章讨论的语言学理论——形态学、句法、语义、音系——在这里都转化为可计算的模型：FST 形态分析、PCFG 句法分析、组合语义、HMM 词性标注。

8.2 语言模型

8.2.1 N-gram 模型

语言模型给任意字符串赋予概率，用于回答“这句话有多自然”。联合概率按链式法则展开：

$$P(w_1, \dots, w_n) = \prod_{i=1}^n P(w_i | w_1, \dots, w_{i-1}) \quad (119)$$

但由于历史词序列太长，实际无法估计，因此引入马尔可夫假设 (n-gram 近似)：

$$P(w_i | w_1, \dots, w_{i-1}) \approx P(w_i | w_{i-n+1}, \dots, w_{i-1}) \quad (120)$$

即“当前词只依赖最近的 $n - 1$ 个词”。bigram($n = 2$) 是最常用的一种。

8.2.2 最大似然估计

$$P(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i)}{C(w_{i-1})} \quad (121)$$

其中 $C(\cdot)$ 是语料中的计数。若某个 bigram 未出现，则概率为零——这会导致整个句子概率为零，因此需要平滑。

8.2.3 平滑技术

平滑技术为未见事件分配非零概率。Add-k 平滑：

$$P_{\text{add-k}}(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i) + k}{C(w_{i-1}) + k \cdot |V|} \quad (122)$$

更先进的平滑方法包括：Good-Turing 估计、Kneser-Ney 平滑 (目前最常用) 以及回退 (back-off) 模型。平滑的本质是对”零计数”事件按频率衰减重新分配概率，同时保持总和为 1。

8.2.4 语言模型与语言差异

语言模型直接反映语言的统计规律：训练自不同语言的语言模型，其 n-gram 分布差异巨大。例如汉语没有词边界 (分词是预处理难题)、日语 n-gram 以”假名/形态素”为单位、形态丰富的语言 (俄语、芬兰语) 词形众多导致数据稀疏。这些差异催生了”子词 (tokenization)”技术 (如 BPE)，成为现代多语言 NLP 的标准做法。

8.3 词性标注

8.3.1 隐马尔可夫模型 (HMM)

词性标注的任务是：给定词序列，推断最可能的词性序列。HMM 假设：

$$P(t_1, \dots, t_n | w_1, \dots, w_n) = \prod_{i=1}^n P(t_i | t_{i-1}) \cdot P(w_i | t_i) \quad (123)$$

- $P(t_i | t_{i-1})$: 转移概率 (词性之间的过渡)
- $P(w_i | t_i)$: 发射概率 (某个词性下出现某个词)

HMM 是一个生成模型：先按转移概率生成词性序列，再按发射概率生成词序列。标注就是求使 $P(t|w)$ 最大的词性序列，用贝叶斯法则：

$$\hat{t} = \arg \max_t \prod_{i=1}^n P(t_i | t_{i-1}) \cdot P(w_i | t_i) \quad (124)$$

8.3.2 Viterbi 算法

HMM 的解码用动态规划。定义 $v_t(j)$ 为”时刻 t 处于状态 j 且路径最优的最大概率”：

$$v_t(j) = \max_i [v_{t-1}(i) \cdot a_{ij}] \cdot b_j(o_t) \quad (125)$$

其中 a_{ij} 是转移概率， $b_j(o_t)$ 是发射概率。同时用回溯指针记录最优路径。Viterbi 时间复杂度 $O(T \cdot |S|^2)$ ，是 NLP 中最经典的算法之一。

8.3.3 词性标注的跨语言差异

不同语言的词性标注难度不同：

- 英语: 形态简单, 歧义主要来自词形相同 (like 可以是动词/介词/形容词)
- 汉语: 无词边界, 分词与标注联合进行; 词性相对稳定
- 俄语/德语: 屈折丰富, 词形本身携带大量信息, 但词形变化大、数据稀疏
- 日语: 词与词之间无空格, 需先形态分析 (分词) 再标注

8.4 词向量表示

8.4.1 分布语义假说

”词的意义由其使用语境决定”(Firth, 1957)。分布语义把词表示为高维向量, 使语义相似性转化为向量距离。

8.4.2 Word2Vec

Word2Vec(Mikolov et al., 2013) 用神经网络从语料学习词向量, 两种架构:

$$\begin{aligned} \text{Skip-gram: } \max_t \sum_{-c \leq j \leq c, j \neq 0} \log P(w_{t+j} | w_t) \\ P(w_O | w_I) = \frac{\exp(v'_{w_O} \top v_{w_I})}{\sum_{w \in V} \exp(v'_w \top v_{w_I})} \end{aligned} \quad (126)$$

Skip-gram 用中心词预测上下文词, 通过 softmax 输出概率。优化用负采样加速 (不遍历整个词表)。

8.4.3 词向量类比

词向量编码了语义关系 (词向量空间中的平移向量对应语义关系):

$$\text{king} - \text{man} + \text{woman} \approx \text{queen} \quad (127)$$

$$\text{king} - \text{man} \approx \text{queen} - \text{woman} \quad (\text{性别关系的平行位移}) \quad (128)$$

8.4.4 多语言词向量

多语言词向量把不同语言映射到同一向量空间，实现跨语言语义对齐：

$$\text{英语} \xrightarrow{\text{线性变换}} \text{西班牙语向量空间} \quad (129)$$

这种对齐 (如 MUSE、VecMap) 使”语言之间的差异”可以被定量刻画：同一概念在不同语言中的向量相近，而语言特有的结构差异反映在对齐误差上。

8.5 句法分析

8.5.1 依存分析

依存分析预测每个词的中心词与关系：

$$P(y|x) = \frac{\exp(w \cdot \Phi(x, y))}{\sum_{y'} \exp(w \cdot \Phi(x, y'))} \quad (130)$$

其中 $\Phi(x, y)$ 是特征向量 (词形、词性、距离等)， w 是权重。这是最大熵/softmax 分类器，可由带标注的树库训练。

8.5.2 转移系统

主流依存分析器 (如 Greedy transition-based parser) 把句法分析建模为状态转移：

$$\begin{aligned} \text{SHIFT: } (\sigma, i|Q, A) &\Rightarrow (\sigma|i, Q, A) \\ \text{LEFT-ARC: } (\sigma|i, j|Q, A) &\Rightarrow (\sigma|i, Q, A \cup \{(j, r, i)\}) \\ \text{RIGHT-ARC: } (\sigma|i, j|Q, A) &\Rightarrow (\sigma|i|j, Q, A \cup \{(i, r, j)\}) \end{aligned} \quad (131)$$

Arc-Eager 系统维护栈 σ 、队列 Q 和已建立弧的集合 A ，每次选择一个操作 (移进/建左弧/建右弧)。贪心解析器用分类器选择下一个动作，复杂度 $O(n)$ 。

8.5.3 跨语言依存分析: Universal Dependencies

Universal Dependencies(UD) 项目为 100+ 语言标注统一的依存关系与词性体系。它的价值在于：用同一套标注体系描述世界语言，使得跨语言句法研究 (依存距离、语序倾向、树结构统计) 成为可能。这正是”跨语言差异的形式化比较”的计算基础设施。

8.6 Transformer 与注意力

8.6.1 自注意力机制

注意力机制让模型动态聚焦输入的相关部分。缩放点积注意力：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V \quad (132)$$

$$\begin{aligned}
Q &= XW_Q \\
K &= XW_K \\
V &= XW_V
\end{aligned}
\tag{133}$$

其中 Q (查询)、 K (键)、 V (值) 是输入 X 经过不同权重矩阵投影的结果, 除以 $\sqrt{d_k}$ 防止 softmax 饱和。

8.6.2 多头注意力

多个注意力头并行捕捉不同关系:

$$\text{MultiHead}(X) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W_O \tag{134}$$

$$\text{head}_i = \text{Attention}(XW_Q^i, XW_K^i, XW_V^i) \tag{135}$$

研究表明不同注意力头分别捕捉句法依存 (主谓关系)、共指、长距离依赖等——注意力模式部分再现了语言学知识 (依存树、语法角色)。Transformer 也因此被称为“隐式学习语法的模型”。

8.6.3 位置编码

自注意力本身对位置不敏感, 需要加入位置编码:

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d}) \tag{136}$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d}) \tag{137}$$

8.7 大语言模型

8.7.1 语言建模目标

大语言模型 (LLM) 的训练目标是自回归语言建模: 最大化给定前文的条件下预测下一词的概率。

$$\mathcal{L} = - \sum_{t=1}^T \log P(w_t | w_{<t}; \theta) \tag{138}$$

这个“预测下一个词”的目标虽然简单, 却迫使模型学习语法、语义、常识和世界知识。

8.7.2 缩放定律

模型性能随参数量、数据量、计算量遵循幂律 (缩放定律, Scaling Laws):

$$L(N, D) = \frac{A}{N^\alpha} + \frac{B}{D^\beta} + E \quad (139)$$

其中 N 是参数量, D 是训练数据量, E 是数据不可约损失, α, β 是幂律指数。

8.7.3 多语言模型

现代 LLM(如 GPT 系列) 同时训练几十上百种语言, 其多语言能力为”语言差异”提供了新的计算视角:

- 模型内部形成了相对”语言中立”的语义表示 (语言共享意义空间)
- 低资源语言受益于跨语言迁移 (从数据多的语言学到模式)
- 模型对相近语言 (英德、中韩) 的迁移效果显著优于远缘语言

这从计算角度验证了语义学一章的结论: 语义结构跨语言共享, 表层编码各异。

8.8 机器翻译

8.8.1 统计机器翻译

基于词的翻译模型:

$$P(e|f) = \sum_a P(f|e, a) \cdot P(e) \quad (140)$$

其中 a 是词对齐。经典 IBM 模型用期望最大化 (EM) 估计对齐概率。

8.8.2 神经机器翻译

Transformer 序列到序列模型直接学习 $P(e|f)$, 端到端训练。注意力让解码器动态对齐源语言的对应片段。机器翻译的性能与语言对之间的距离相关: 近缘语言对 (英法) 容易, 远缘类型 (英日、中英) 难——语言差异的量化体现在翻译难度上。

8.9 评估指标

8.9.1 困惑度 (Perplexity)

困惑度衡量语言模型的不确定度:

$$\text{PPL}(W) = \sqrt[N]{\frac{1}{P(w_1, \dots, w_N)}} = 2^{-\frac{1}{N} \sum_{i=1}^N \log_2 P(w_i|w_{<i})} \quad (141)$$

困惑度越低越好 (模型越确定)。注意 PPL 只能比较同一 token 化方案下的模型。

8.9.2 BLEU 分数

BLEU 衡量机器翻译与参考译文的 n -gram 重合度：

$$\text{BLEU} = \text{BP} \cdot \exp \left(\sum_{n=1}^N w_n \log p_n \right) \quad (142)$$

其中 p_n 是 n -gram 精确率，BP 是惩罚过短译文的”简短惩罚”。

8.9.3 跨语言评估的挑战

不同语言的评估难度不同：形态丰富的语言 (俄语)BLEU 对词形变化敏感；汉语、日语无空格分词影响 token 化；这些技术性差异本身也是”语言差异”的一部分。

8.10 计算语言学与语言学的相互反哺

计算语言学不只是应用语言学知识，它也反哺理论语言学：

- **验证理论**：依存分析器、词向量在数据上检验了语言学假说 (主谓优先、距离倾向)
- **发现模式**：大规模多语言模型揭示了语言共性 (如依存距离的普遍最短化倾向)
- **量化差异**：语料库方法把”语言差异”从定性描述变成可测度的数值 (语素密度、语序倾向、依存距离)

8.11 本章小结

计算语言学把前几章的语言学理论转化为可计算的模型：语言模型刻画词汇的统计规律，HMM 和 Viterbi 做词性标注，Word2Vec 与 Transformer 学习语义表示，依存分析器与 UD 项目做跨语言句法分析，LLM 通过下一个词预测隐式习得语法。计算视角下，”语言差异”成为可以定量测量的对象——而所有现代系统都验证了一个结论：语言共享深层结构，差异在表层参数与统计分布。

至此，我们已经系统学习了语言学各核心领域的理论。最后一章把这些视角整合起来，专门讨论不同语言之间的差异：差异有哪些维度、如何形式化、以及为什么语言既”各不同”又”都一样”。

9 跨语言比较: 不同语言的差异

这是本书的总结章，也是核心关注的焦点。前面各章从不同层面建立了语言学的工具，本章把它们整合起来，系统地回答一个问题：不同的语言到底差在哪里？我们会看到，语言的差异是多维度、系统性的，但同时受到强烈约束——语言在共享深层结构的前提下，以有限的方式参数化地彼此不同。

9.1 比较语言的维度

表 22: 语言差异的比较维度

维度	内容	相关章节
语音/音系	音位库存、声调、音节结构	音系学与语音学
词法	形态类型、格/数/性/时体系统	词法
句法	语序、头参数、话题/主语结构	句法
语义-词汇	词义切分、语法化、敬语	语义学
文字	文字类型、正字法	(本章)
语用	话题结构、信息结构、间接言语行为	(本章)

比较方法上，除了定性描述，现代类型学用量化指标比较语言：语素密度、基本语序分布、音位库存大小、依存距离等，都可以从语料库中自动计算。语言之间的”差异距离”也因此可以定义为一个多维向量空间中的距离。

9.2 语音层面的差异

9.2.1 音位库存的规模差异

不同语言的音位数量差异巨大。根据 UPSID 数据库：

- 音位少的语言: 夏威夷语 (约 13 个音位)、皮拉罕语
- 音位中等的语言: 英语 (约 44 个音位)、汉语普通话 (约 21 辅音 +6 元音 +4 声调)
- 音位多的语言: !Xóõ 语 (非洲，辅音音位数百个，含复杂的搭嘴音)、高加索语言 (辅音密集)

元音系统差异尤其直观：日语 5 个元音、英语 15 个左右、越南语 11 个、某些德语方言有 20 个以上。

9.2.2 送气对立: 一音两用 vs 两音对立

- 英语: 送气与不送气同属一个音位 (变体分布, 不区分意义)
- 印地语、泰语: 送气与不送气是不同音位 (*pal* vs *phal* 区分词义)
- 汉语普通话: /p/ /p^h/ 送气对立区分词义 (“爸” vs “怕”)

英语: [p] ~ [p^h] = /p/ (同一音位) 汉语: /p/ ≠ /p^h/ (143)

9.2.3 声调的有无

- 声调语言: 汉语 (4 调)、泰语 (5 调)、越南语 (6 调)、约鲁巴语 (3 调)
- 音高重音语言: 日语、瑞典语 (词内调峰位置区分词义)
- 重音语言: 英语、俄语、德语、西班牙语 (重音位置或固定或自由)

英语母语者听汉语“妈/麻/马/骂”觉得是同一音节的不同“语气”，而汉语母语者听英语重音差异如“REcord”(名词) / “reCORD”(动词) 也难以掌握——两种语言的韵律系统结构不同。

9.2.4 音节结构差异

表 23: 音节结构对比

语言	最大音节	允许辅音丛	例
汉语普通话	(C)V(N)	否	天 tiān
日语	(C)(y)V(N/Q)	否	東京 tōkyō
英语	CCCVCCCC	是	strengths
波兰语	CCCCVCCCC	是 (极复杂)	bezwzględny

音节模板决定了“外来词改造”的方式: 英语单词进入日语被拆成开音节 (computer → コンピューター), 进入汉语被套进 (C)V(N) 模板并加上声调。

9.3 词法层面的差异

9.3.1 形态类型谱系

语言在”一个词携带多少语法信息”上差异极大，构成一个连续谱：

孤立 (汉语) → 黏着 (日语、土耳其语) → 屈折 (俄语、德语) → 复综 (因纽特语)
(144)

例子 9.1 (同一句”我吃”在不同语言的形态差异).

汉语：我吃 (零形态，靠语序和代词) (145)

英语：I eat (少数屈折：第三人称-s) (146)

日语：食べる (黏着词缀堆叠：食べ-る) (147)

俄语：Я ем (动词变位融合人称-数-时) (148)

拉丁语：edō (一个词尾融合所有语法信息) (149)

9.3.2 名词的性: 语义 vs 语法

- 无语法性: 汉语、日语、土耳其语、英语 (基本没有)
- 两性: 法语、西班牙语、意大利语 (阴阳)
- 三性: 德语、俄语、拉丁语 (阴阳中)
- 多类: 斯瓦希里语 (名词类别系统，约 10 类)、班图语言

语法性 (grammatical gender) 与自然性别不一定对应：德语 Mädchen(女孩) 是中性的。跨语言比较中，同一个物体可以有不同的性：月亮在拉丁语、俄语是阴性，在德语是阳性。

9.3.3 格的系统: 从语序到词形

表 24: 格系统对比

语言	名词格	表达方式	例 (宾格)
汉语	无	语序	猫吃鱼 / 鱼吃猫
英语	仅代词保留	语序 + 残存代词格	him
日语	有 (助词)	后置助词	魚を食べる
德语	4 格	冠词 + 名词词尾	den Fisch
俄语	6 格	名词词尾	рыбу
芬兰语	15 格	名词词尾	kalaa

格与语序的关系是类型学的经典发现：格标记越丰富，语序越自由。俄语、拉丁语格标记完备，语序可以相当自由 (靠格判断谁吃谁)；汉语无语标记，语序成为唯一手段 (“猫吃鱼” 不能换序为 “鱼吃猫”)。

$$\text{形态格标记强度} \propto \text{语序自由度}$$

(150)

9.3.4 动词的时体系统

- 英语: 时态 (现在/过去)+ 体态 (进行/完成) 通过形态组合，将来时用助动词
- 汉语: 无时态形态，用时间词和体助词 “了/着/过” 表达
- 俄语: 完成/未完成体是词汇-语法对 (читать 读/прочитать 读完)，过去时用词形
- 日语: 时态 (-た过去)+ 体态 (-ている进行/持续)

例子 9.2 (“我读了书” 的跨语言编码).

- 英语: *I read the book* (时态形态) (151)
- 汉语: 我读了书 (体助词 “了”) (152)
- 日语: 本を読んだ (时态词尾 -だ) (153)
- 俄语: *Я прочитал книгу* (完成体前缀 *про-*) (154)

9.4 句法层面的差异

9.4.1 基本语序

表 25: 语序差异及代表语言

语序	代表语言	例句 (我吃苹果)
SVO	英语、汉语、法语、俄语	I eat an apple
SOV	日语、土耳其语、印地语	私はりんごを食べる
VSO	阿拉伯语、威尔士语	(书面阿拉伯语 أَكُلُ التفاحة)

9.4.2 头参数: 语序的系统性

中心词的位置是 “一把钥匙”，一次决定多种结构的语序。比较英语 (中心词在前) 与日语 (中心词在后)：

表 26: 头参数的连锁效应

结构	英语 (中心词前)	日语 (中心词后)
动词 + 宾语	eat an apple	りんごを食べる
介词 + 名词	in the house	家の中 (名词 + 助词)
名词 + 属格	the book of John	ジョンの本
名词 + 关系从句	the book that I read	私が読んだ本
形容词 + 名词	red car	赤い車

注意头参数不是铁律: 汉语是 SVO(中心词前) 却用后置结构(“桌子上”), 属于“混合型”。但作为一个统计规律, 头参数解释了英语与日语、土耳其语在几乎所有结构上的镜像语序。

9.4.3 主语优先 vs 话题优先

- **主语优先 (Subject-prominent):** 句子以“主语-谓语”为骨架。英语、日语、印欧语系语言
- **话题优先 (Topic-prominent):** 句子以“话题-说明”为骨架。汉语、朝鲜语、日语
汉语的“话题”可以不是动词的施事:

这本书, 我已经读完了 (话题“这本书”是受事) (155)

英语必须把它改为被动或补出受事: “I have already read this book” / “This book has been read”。话题优先语言允许大量“无主语句”, 且话题可以直接接评论, 这在主语优先语言中不合语法。

9.4.4 Pro-省略 (主语省略)

- **可省略主语语言 (pro-drop):** 西班牙语、意大利语、日语、汉语
- **不可省略主语语言 (non-pro-drop):** 英语、法语、德语

例子 9.3.

意大利语: *Vado.* (我) 去。 (156)

日语: 行く。(我/你/他…) 去。 (157)

英语: **Go.* (不合语法, 必须说 *I go / You go*) (158)

pro-drop 源于丰富的动词屈折 (意大利语动词变位已标明主语人称) 或话题结构 (日语、汉语靠语境确定主语)。英语动词形态简化 (几乎只有-s), 失去省略主语的条件。

9.4.5 疑问句的形成

表 27: 是非疑问句的形成方式

方式	代表语言	例
助动词移位	英语	Are you ready?
句末语气词	汉语、日语	你准备好了吗?
动词前置	波兰语 (部分)	Czy jesteś gotowy?
词尾形态	日语	行きますか

9.4.6 Wh-疑问词的位置

- 疑问词移动: 英语 (What did you buy __?), 德语、法语
- 疑问词原位 (Wh-in-situ): 汉语 (你买了什么?), 日语、韩语

虽然表层差异大, 但深层一致: 英语的 __ 位置和汉语的” 什么” 位置在逻辑上完全相同 (都是宾语), 区别只在” 是否把疑问词提前”。这就是” 普遍结构 + 参数” 的典范。

9.4.7 关系从句

- 后置关系从句: 英语、法语、德语 (the book that I read)
- 前置关系从句: 日语、汉语、朝鲜语 (私が読んだ本、” 我读的书”)

关系从句位置与头参数一致: 中心词在后语言把关系从句放在名词前。这也产生著名的处理难点——前置关系从句的中心名词在从句之后才出现, 读者需要” 悬置” 信息。

9.5 代词、敬语与礼貌系统

9.5.1 第二人称的复杂性差异

- 英语: 只有一个 you(不分单复、不分敬俗, 600 年前有 thou/you 区分)
- 法语/西班牙语: tu/vous, tú/usted(亲昵/礼貌二分)
- 汉语: 你/您 (礼貌), 普通话无复数区分 (口语” 你们/您们”)
- 日语: 多个代词 + 敬语系统 (见下)

9.5.2 敬语系统: 日语的极端例子

日语敬语 (敬語) 分为三种, 是跨语言差异中最复杂的礼貌系统之一:

- 尊敬語 (そんけいご): 抬高对方 (いらっしゃる = いる/行く/来る的尊敬形)
- 謙讓語 (けんじょうご): 贬低自己 (参る = 行く/来る的自谦形)
- 丁寧語 (ていねいご): 礼貌体 (です/ます)

先生が来る $\xrightarrow{\text{尊敬}}$ 先生がいらっしゃる (159)

朝鲜语也有复杂的敬语阶系统 (等级由说话双方的社会关系决定), 英语则几乎完全依赖词汇选择 (polite/please)。敬语系统反映的是语言背后的社会结构——语言差异不只是结构差异, 也是文化差异。

9.6 文字系统的差异

9.6.1 文字类型学

表 28: 文字类型

文字类型	表示单位	代表
字母文字 (Alphabet)	音素	拉丁字母、西里尔字母
元音附标文字 (Abjad/Abugida)	辅音 (+ 元音附标)	阿拉伯文、希伯来文、天城文
音节文字 (Syllabary)	音节	日文假名、切罗基文
语素文字 (Logographic)	词/语素	汉字

9.6.2 汉字与拼音文字的结构差异

- 汉字: 语素-音节文字, 一字对应一个音节 + 一个语素; 形声字占多数 (意符 + 声符, 如”清”= 水 + 青)
- 假名: 日语音节文字 (五十音), 与汉字混用 (汉字表实义词、假名表语法词缀)
- 谚文: 韩语字母文字, 把音素拼成方块字 (ㄱ + ㅏ + ㅓ = ㅓ)
- 拉丁字母: 音素文字, 拼写与发音的关系因语言而异 (意大利语几乎一一对应, 英语拼写与发音严重脱节)

9.6.3 文字与语言结构的互动

文字类型并非随机: 孤立语 (汉语) 用一字一语的语素文字效率高; 形态丰富的语言 (俄语) 用音素文字便于表达词形变化 (同一词根的不同变格直接可见)。日语混合使用汉字 (实词) 与假名 (词缀) 来应付黏着形态, 是文字与语言类型”适配”的典型案例。

9.7 词汇与语法化的差异

9.7.1 词义切分的不同

语言以不同的方式切分概念世界:

英语: hand arm 日语: 手 (て) 腕 (うで) 同域 (160)

颜色、亲属、时间、空间等领域都是词义切分差异的经典例子 (颜色词的普遍进化层级)。

9.7.2 语法化的差异

实词虚化为语法成分的过程 (语法化) 在不同语言中路径不同:

汉语: ”把”(手抓) → 处置介词 (把书放) 英语: ”have” → 完成助动词 (161)

汉语”了”从”完结”义动词语法化为体助词, 英语 be going to 从”移动”语法化为将来时标记——同样的语法化倾向, 不同语言的实现路径不同。

9.8 形式化: 原则与参数理论

9.8.1 语言差异 = 参数取值

乔姆斯基的原则与参数理论 (P&P) 为语言差异提供形式化框架: 普遍语法提供原则 (各语言共享), 语言之间的差异是少量参数的取值不同。

$$\text{语言 } L = \langle \text{普遍原则 } P, \text{参数向量 } \Theta(L) \rangle \quad (162)$$

表 29: 参数化差异 (示例)

参数	英语	汉语	日语	西班牙语
头参数	中心词前	(混合)	中心词后	中心词前
主语省略	否	是 (话题)	是	是
疑问词	移动	原位	原位	移动
格标记	弱	无	助词	中
声调	无	有 (4 调)	音高重音	无

这个框架的意义在于：儿童习得语言时，不需要学习”整套语法”，只需要根据输入设定参数值。语言差异被压缩为少数二进制开关——这是对”语言为何既相似又不同”最简洁的解释。

9.8.2 跨语言共性与蕴含层级

语言差异不是任意的，普遍共性约束着差异。格林伯格共性和蕴含层级在差异中建立秩序：

若VSO ⇒ 前置词; 格系统按层级 主格 < 宾格 < 与格 < ... (163)

统计上，语言有强烈的”默认设置”倾向：SOV 和 SVO 占绝大多数、绝大多数语言动词紧跟主语或宾语、依存距离普遍保持最短。差异被强烈约束在少数”参数空间”中。

9.9 语言相对性: 差异是否影响思维?

9.9.1 萨丕尔-沃尔夫假说

语言差异是否影响说话者的思维方式？萨丕尔-沃尔夫假说 (Sapir-Whorf Hypothesis) 有强 (语言决定思维) 与弱 (语言影响思维) 两个版本。

- 强版 (语言决定论): 已被广泛否定——人类普遍可以表达任意概念，任何语言都能表达新观念
- 弱版 (语言相对论): 有实验支持——语言习惯影响注意与记忆的方式

9.9.2 相对论的实验证据

- 颜色: 有基本颜色词的语言，说话者对颜色范畴的辨别更快
- 空间: 某些原住民语言用绝对方向 (东西南北) 而非相对方向 (左右) 描述空间，说话者的空间记忆方式随之不同

- 性别: 语法性影响说话者对无生命物的联想 (德语桥是阴性、西班牙语桥是阳性)

9.9.3 现代计算的视角

大语言模型的多语言能力表明：不同语言可以表达完全相同的语义内容 (可互相翻译), 支持” 意义共享” 立场。语言差异主要影响编码的效率与习惯，而非表达能力本身。

9.10 语言差异的量化比较

现代计算类型学把差异转化为可测量指标，用距离度量语言：

语言距离 $d(L_1, L_2) = \sqrt{\sum_i w_i \cdot (F_i(L_1) - F_i(L_2))^2}$ (164)

其中 F_i 是类型学特征 (语序、格标记、声调有无等), w_i 是权重。语系距离 (词汇相似度)、语音距离 (音位对应)、类型距离 (结构特征) 共同刻画两种语言的” 差异度”。例如英语与德语距离小 (同族同类型), 英语与日语距离大 (不同族、类型迥异: SVO/孤屈折 vs SOV/黏着)。

表 30: 英日对比: 差异的维度总览

维度	英语	日语
语系	印欧-日耳曼	(独立/争议)
形态	弱屈折	黏着
语序	SVO	SOV
介词	前置词	后置助词
格标记	弱 (语序)	强 (助词)
声调	无	音高重音
主语省略	否	是
疑问词	移动	原位
敬语	无系统	复杂系统
文字	拉丁字母	汉字 + 假名

9.11 本章小结

不同语言之间的差异是多维度的，但也是系统性的、受约束的：

- 差异在表层: 语音、词法、语序、文字——语言在最直观的层面差异巨大
- 共藏在深层: 论元结构、组合语义、递归句法、普遍约束——所有语言共享

- **差异可参数化:** 原则与参数理论把差异压缩为参数向量, 优选论把音系差异归约为约束排序
- **差异可量化:** 计算类型学让”语言距离”成为可测量的数量

因此, ”语言的差异”与”语言的共性”是同一枚硬币的两面: 差异是表层参数的选择, 共性是深层结构的约束。理解了这一点, 就掌握了语言学的精髓——从汉语的孤立语形态、英语的 SVO 语序、日语的黏着与敬语、俄语的格系统、阿拉伯语的 VSO 与声调, 到所有语言共享的递归性与组合原则。

本书到此结束。我们从语言学的历史出发, 历经形式语言、形态、句法、语义、音系与计算语言学, 最终回到语言学的根本问题: 语言是什么, 以及语言如何既丰富多彩又和谐统一。